

Reduccion de Dimensionalidad: Conexion de PCA y SVD.

* La Maldición de la Dimensionalidad: En datasets masivos de minería de datos (ej. genómica, procesamiento de imágenes, registros de texto), las observaciones viven en espacios de dimensionalidad muy alta D .

* Aprendizaje No Supervisado: A diferencia del aprendizaje supervisado, solo disponemos del conjunto de vectores observados $X = \{x_1, x_2, \dots, x_N\}$ sin etiquetas de salida y .

* Propósito de PCA: Proyectar ortogonalmente los datos desde RD hacia un subespacio lineal de menor dimensión RM ($M \ll D$) preservando la máxima variabilidad y estructura de información posible.

$$X \in \mathbb{R}^{N \times D} \text{ (datos en bruto)} \rightarrow X' \in \mathbb{R}^{N \times K} \text{ (datos reducidos)} \quad \text{donde } \boxed{K \ll D}$$

SINGULAR VALUE DECOMPOSITION (SVD)

$$\tilde{a} = \begin{bmatrix} 1 \\ 3 \end{bmatrix} \quad A = \begin{bmatrix} 2 & 1 \\ -1 & 1 \end{bmatrix} \quad \tilde{b} = A\tilde{a} = \begin{bmatrix} 2 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 5 \\ 2 \end{bmatrix}$$


que ha pasado al multiplicar $\tilde{a}$ por A



si queremos rotar un ángulo específico $A = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$

si queremos extender $\tilde{a}$ $A = \begin{bmatrix} \alpha & 0 \\ 0 & \alpha \end{bmatrix}$

$$\tilde{b}_1 = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 3 \\ 6 \end{bmatrix}$$



esfera en 2D

$$A \in \mathbb{R}^{n \times n}$$

Esfera n -dimensional

$$\{\tilde{u}_1, \tilde{u}_2, \dots, \tilde{u}_n\}$$

elipse de n -dimensional

$$\{\hat{u}_1, \hat{u}_2, \dots, \hat{u}_n\} \text{ vectores unitarios ortogonales}$$

$$\{\sigma_1, \dots, \sigma_n\} \text{ factores de cambio}$$

¿cómo lo relacionamos lo λ ?

$$A\tilde{u}_i = \sigma_i \hat{u}_i$$

$$A\tilde{v} = \lambda \tilde{v}$$

$$A\tilde{v}_i = \sigma_i \hat{v}_i \quad \{i=1, \dots, n\}$$


$$[A] [\tilde{u}_1, \tilde{u}_2, \dots, \tilde{u}_n] = [\hat{u}_1, \hat{u}_2, \dots, \hat{u}_n] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix}$$

$$A\tilde{v} = \underbrace{\tilde{U} \tilde{\Sigma}}_{\text{Transformación unitaria}} \tilde{v} \quad \begin{matrix} \text{factor de modificación} \\ \tilde{v}' = \tilde{v}^T \\ \tilde{u}' = \tilde{u}^T \end{matrix}$$

$$\text{si } A\tilde{v}_i' = \tilde{U} \tilde{\Sigma} \tilde{v}_i'$$

$$\boxed{A = \tilde{U} \tilde{\Sigma} \tilde{V}^T} \text{ reduced singular value decomposition}$$

¿Qué hace la matriz A ? rotar y cambiar el tamaño de los ejes



(SVD) toda matriz A tiene una descomposición en valores singulares

- los valores singulares (σ_i) están determinados de forma única y si A es cuadrada $\{\sigma_i\}$ es distinto
- $\{\hat{u}_i\}$ y $\{\hat{v}_i\}$ también en único salvo un signo menos

cómo computamos $A = (U \tilde{\Sigma} V^T)$


$$\begin{aligned} A^T A &= (U \tilde{\Sigma} V^T)^T (U \tilde{\Sigma} V^T) \\ &= V \tilde{\Sigma} V^T U \tilde{\Sigma} V^T \\ &= V \tilde{\Sigma} \tilde{\Sigma}^T V^T = V \end{aligned}$$

$$A^T A \tilde{v} = V \tilde{\Sigma}^2 V^T \tilde{v}$$


$$\underbrace{A^T A \tilde{v}}_{A \tilde{x}} = V \tilde{\Sigma}^2 \tilde{v} \quad \boxed{\lambda_i = \sigma_i^2}$$

$$A A^T U = U \tilde{\Sigma}$$

Principal Component Analysis (PCA)



Camera 1



Camera 3

$$F = m a$$

$$-m \frac{d^2 x}{dt^2}$$

$$f(x) = A \cos(\omega t + \omega_0) + (\sigma_{\text{residuo}})$$

considerando un sistema ideal

- no hay resistencia del aire
- el resorte tampoco se deforma
- etc.

$$\text{cámara 1 } (\bar{x}_1, \bar{y}_1)$$

$$\text{cámara 2 } (\bar{x}_2, \bar{y}_2)$$

$$\text{cámara 3 } (\bar{x}_3, \bar{y}_3)$$

$$\bar{X} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \bar{x}_3 \\ \bar{y}_1 \\ \bar{y}_2 \\ \bar{y}_3 \end{bmatrix}$$

• Tendido
• redundancia

Varianza y covarianza

$$\bar{a} = (a_1, a_2, \dots, a_n)$$

$$\bar{b} = (b_1, \dots, b_n)$$

varianza

$$\sigma_a^2 = \frac{1}{n-1} \bar{a} \bar{a}^T$$


$$\sigma_b^2 = \frac{1}{n-1} \bar{b} \bar{b}^T$$

covarianza

$$\sigma_{ab} = \frac{1}{n-1} \bar{a} \bar{b}^T$$

si está en la misma dirección se obtiene máxima covarianza


si la covarianza es cero son ortogonales



$\text{cov} > 0$



$\text{cov} < 0$



$\text{cov} = 0$

$$C_X = \frac{1}{n-1} X X^T$$

$$6 \times 6 \quad C_X = \begin{bmatrix} \sigma_{x_1 x_1}^2 & \sigma_{x_1 x_2}^2 & \sigma_{x_1 x_3}^2 \\ \sigma_{x_2 x_1}^2 & \sigma_{x_2 x_2}^2 & \sigma_{x_2 x_3}^2 \\ \sigma_{x_3 x_1}^2 & \sigma_{x_3 x_2}^2 & \sigma_{x_3 x_3}^2 \end{bmatrix}$$


$$|| \det(D) ||$$

$$K = \frac{\lambda_{\max}}{\lambda_{\min}}$$

$$\lambda_1 \dots \lambda_D$$

$$K$$

$$K \ll D$$



$$K \sim \frac{\lambda_{\max}}{\lambda_{\min}} \sim \frac{80}{1}$$

¿cómo computamos X ?

$$X X^T = S \Lambda S^T \quad \text{S: matriz n (w) columnas de } X X^T$$

$$S^{-1} = S^T$$

(Λ) .. matriz diagonal con autovalores de $X X^T$

$$Y = S^T X \quad \text{datos originales}$$

$$C_Y = \frac{1}{n-1} Y Y^T$$

$$= \frac{1}{n-1} (S^T X) (S^T X)^T$$

$$= \frac{1}{n-1} S^T X X^T S$$

$$= \frac{1}{n-1} S^T \frac{S \Lambda S^T}{\frac{1}{n-1}} S = \frac{1}{n-1} \Lambda$$

$$\boxed{\Lambda}$$

Consideramos un conjunto de datos $X = \{x_1, x_2, \dots, x_N\}$ con $x_n \in \mathbb{R}^D$, representado como una matriz $X \in \mathbb{R}^{N \times D}$ donde cada fila es una observación centrada $(x_n - \bar{x})^T$. La matriz de covarianza muestral $S \in \mathbb{R}^{D \times D}$ se define como:

$$S = \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(x_n - \bar{x})^T = \frac{1}{N} X^T H X \quad (1)$$

donde $H = I_N - \frac{1}{N} \mathbf{1} \mathbf{1}^T$ es la matriz centradora.

Ejercicio 1: Propiedades de la Matriz de Covarianza y el Teorema Espectral

Sea $S \in \mathbb{R}^{D \times D}$ la matriz de covarianza muestral de un conjunto de datos en $\mathbb{R}^D$.

- Demuestre que S es simétrica y semidefinida positiva ($S \succeq 0$).
- Enuncie y explique el Teorema Espectral para escribir la descomposición de S .
- Demuestre que todos los autovalores λ_i de S son reales y no negativos ($\lambda_i \geq 0$).
- Demuestre que autovectores asociados a autovalores distintos son estrictamente ortogonales.

Demostración / Solución Detallada

a) Simetría y Semidefinida Positiva:

$$\bullet \text{ Simetría: } S^T = \left(\frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(x_n - \bar{x})^T \right)^T = \frac{1}{N} \sum_{n=1}^N ((x_n - \bar{x})^T)^T (x_n - \bar{x})^T = S.$$

$u_i^T S u_i = u_i^T (\lambda_i u_i) = \lambda_i (u_i^T u_i) = \lambda_i$

donde u_i (las columnas de P) son los autovectores ortogonales de S , cumpliendo $u_i^T u_j = \delta_{ij}$.

c) No negatividad de los Autovalores ($\lambda_i \geq 0$): Sea u_i el i -ésimo autovector unitario de S asociado a λ_i , tal que $S u_i = \lambda_i u_i$ y $u_i^T u_i = 1$. Multiplicando por u_i^T a la izquierda:

$$u_i^T S u_i = u_i^T (\lambda_i u_i) = \lambda_i (u_i^T u_i) = \lambda_i$$

Dado que $S \succeq 0$, sabemos por la parte (a) que $u_i^T S u_i \geq 0$. Por lo tanto, $\lambda_i \geq 0$ para todo $i = 1, \dots, D$.

d) Ortogonalidad de Autovectores: Sean u_i, u_j dos autovectores con autovalores distintos $\lambda_i \neq \lambda_j$. Evaluamos la cantidad $u_i^T S u_j$:

$$u_i^T S u_j = u_i^T (\lambda_j u_j) = \lambda_j (u_i^T u_j)$$

$$u_j^T S u_i = (S^T u_i)^T u_j = (S u_i)^T u_j = (\lambda_i u_i)^T u_j = \lambda_i (u_i^T u_j)$$

Restando ambas ecuaciones:

$$(\lambda_i - \lambda_j) (u_i^T u_j) = 0$$

Como $\lambda_i \neq \lambda_j \implies \lambda_i - \lambda_j \neq 0$, se deduce necesariamente que $u_i^T u_j = 0$.