

Curso de Minería de Datos CC442

Clase 2


Prof. Marcos Alania

Fundamentos del Preprocesamiento de Datos

1. **Axioma del Data Scientist:** El 80% del esfuerzo se concentra en la curación y transformación de datos.
2. **Condicionamiento Métrico:** Los teoremas de convergencia en ML dependen de espacios métricos bien condicionados.
3. **Naturaleza de la Transformación:** Operadores algebraicos y probabilísticos sobre la matriz $D_{n \times d}$.
4. **Objetivo:** Transitar de datos ruidosos/incompletos a representaciones con propiedades espectrales deseables.

El Preprocesamiento de Datos:
Una Transformación Topológica y Métrica

$$X_{\text{procesado}} = \mathcal{T}(X_{\text{crudo}}) \quad d(x_i, x_j) \approx d(\mathcal{T}(x_i), \mathcal{T}(x_j))$$




Calidad de Datos: Formalización Probabilística del Ruido

1. **Error de Medición:** Desviación entre la observación x_{obs} y el valor latente x_{real} .
2. **Modelo de Aditividad:** El ruido se modela comúnmente como un proceso estocástico gaussiano.
3. **Sesgo vs. Precisión:** Diferenciación entre errores sistemáticos y varianza aleatoria.
4. **Consecuencia:** El ruido difumina la frontera de decisión, aumentando el riesgo empírico.

La Dualidad Calidad-Ruido: Un Enfoque Probabilístico


$$X_{obs} = X_{true} + \epsilon$$
$$\epsilon \sim \mathcal{N}(0, \Sigma_{ruido})$$



Impacto del Ruido en la Estructura de Varianza

1. **Inflación de la Varianza:** El ruido aditivo incrementa artificialmente la dispersión observada.
2. **Efecto en la Matriz de Covarianza:** Introducción de autovalores espurios en el espectro.
3. **Degradación de PCA:** El ruido puede ser confundido con componentes de alta varianza.
4. **Supuesto de Independencia:** $\epsilon \perp X_{\text{real}}$ permite la descomposición de la covarianza.

$$\text{Var}(X_{\text{obs}}) = \text{Var}(X_{\text{true}}) + \sigma_{\text{ruido}}^2$$
$$\Sigma_{\text{obs}} = \Sigma_{\text{true}} + \sigma^2 I \implies \lambda_{i,\text{obs}} = \lambda_{i,\text{true}} + \sigma^2$$




Detección de Outliers 1D: El Límite de Shewhart

1. **Z-Score:** Estandarización para medir desviaciones en unidades de sigma.
2. **Criterio de 3σ :** En distribuciones normales, solo el 0.27% de los datos excede este umbral.
3. **Efecto de Enmascaramiento (Masking):** Outliers extremos inflan σ , ocultando a otros outliers menos extremos.
4. **Robustez:** Sensibilidad de la media y desviación estándar ante valores aberrantes.

$$z_i = \frac{x_i - \mu}{\sigma}$$

Outlier if $|z_i| > 3 \implies P(|Z| > 3) \approx 0.0027$


$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i \xrightarrow{x_{\text{outlier}} \rightarrow \infty} \infty$$



Detección N-D: Geometría de la Distancia de Mahalanobis

1. **Limitación Euclídea:** Ignora la correlación entre variables y la forma de la distribución.
2. **Métrica de Mahalanobis:** Normaliza el espacio según la estructura de la covarianza Σ .
3. **Interpretación Geométrica:** Σ^{-1} actúa como un operador que rota y aplana el elipsoide de datos en una hiperesfera unitaria.
4. **Invariancia de Escala:** Es robusta ante cambios en las unidades de medida.

$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})}$$
$$(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) = c^2 \quad (\text{Hiper-elipsoide})$$



Modelado de Valores Faltantes: Taxonomía de Rubin

1. MCAR (Missing Completely at Random):

La falta de datos es independiente de cualquier variable observada o no observada.

$$\text{MCAR: } P(R|X_{obs}, X_{miss}) = P(R)$$




$$\text{MAR: } P(R|X_{obs}, X_{miss}) = P(R|X_{obs})$$

$$\text{MNAR: } P(R|X_{obs}, X_{miss}) \text{ depende de } X_{miss}$$

2. MAR (Missing at Random): La probabilidad de ausencia depende de variables observadas, pero no del valor faltante en sí.

3. MNAR (Missing Not at Random): El mecanismo de "pérdida" está vinculado al valor latente (Datos No Ignorables).


4. Peligro: Imputar bajo MNAR sin un modelo de selección introduce sesgos sistemáticos en la distribución conjunta $P(X)$.

MCAR (Completamente al Azar)	MAR (Al Azar)	MNAR (No al Azar)
Independencia total. La ausencia no depende de ninguna variable.	Dependencia observable. La ausencia se explica por otras variables conocidas.	Dependencia latente. La ausencia depende del propio valor faltante.
		

Imputación Univariada: La Trampa de la Media

1. **Mecanismo:** Sustitución de $x_{missing}$ por el estimador de tendencia central μ_{obs} .
2. **Atractivo:** Facilidad de implementación y preservación de la media global de la muestra.
3. **Costo Oculto:** Distorsión severa de la forma de la distribución.
4. **Efecto:** Creación de picos artificiales (Dirac delta-like) en la densidad de probabilidad.


$$\hat{x}_i = \bar{x}_{obs} = \frac{1}{n} \sum_{j \in \text{Obs}} x_j$$
$$\mathbb{E}[\bar{X}_{new}] = \mathbb{E}[\bar{X}_{obs}]$$



Colapso de la Varianza e Impacto en Clasificadores

1. **Subestimación:** La varianza imputada es estrictamente menor que la varianza original.
2. **Factor de Deflación:** Proporcional a la tasa de valores faltantes.
3. **Riesgo en SVM:** El colapso de la varianza estrecha artificialmente los márgenes de separación.
4. **Sobreajuste:** El modelo interpreta la falta de varianza como una señal de alta confianza, ignorando la incertidumbre real.


$$\sigma_{new}^2 = \frac{n}{n+m} \sigma_{obs}^2$$



Media vs. Mediana: Estimadores L2 vs. L1

1. **Media (L2):** Minimiza la suma de errores al cuadrado; esclava de los outliers.
2. **Mediana (L1):** Minimiza la suma de errores absolutos; estadísticamente robusta.
3. **Sesgo de Outlier:** Un solo valor extremo desplaza la media pero no la mediana.
4. **Recomendación:** Usar mediana en distribuciones asimétricas (skewed).

$$\mu = \arg \min_c \sum (x_i - c)^2 \quad (\text{Sensible a } \Delta^2)$$
$$\tilde{x} = \arg \min_c \sum |x_i - c| \quad (\text{Robusto})$$




Degradación de la Estructura de Covarianza

1. **Atenuación de Correlaciones:** La imputación simple diluye las relaciones entre variables.
2. **Efecto en PCA:** Los autovectores (ejes) rotan hacia las variables con mayor integridad de datos.
3. **Ruido Estructural:** Se introducen correlaciones espurias o se ocultan dependencias reales.
4. **Consecuencia:** El análisis de componentes principales captura la 'limpieza' del dato en lugar de su 'señal'.

$$\text{Cov}_{new}(X, Y) \approx \frac{n}{n+m} \text{Cov}_{obs}(X, Y)$$


$\Sigma_{new} \neq \Sigma_{true} \implies$ Rotación de Autovectores



Imputación Multivariada y Modelos Predictivos

1. **Concepto:** Tratar la imputación como un problema de aprendizaje supervisado.
2. **Regresión Lineal:** Estimar el faltante en X_j usando las demás columnas $\mathbf{X}_{-j}$ como predictores.
3. **Preservación de σ :** Mantiene mejor la estructura de correlación que la media simple.
4. **MICE:** Proceso iterativo de imputaciones encadenadas para converger a $P(\mathbf{X})$.


$$\hat{x}_{ij} = \beta_0 + \sum_{k \neq j} \beta_k x_{ik}$$
$$\boldsymbol{\beta} = (\mathbf{X}_{-j}^T \mathbf{X}_{-j})^{-1} \mathbf{X}_{-j}^T \mathbf{y}_j$$



Resumen: La Limpieza como Operador Espectral

1. **Advertencia Final:** Todo operador de limpieza $\mathbf{T}(\mathbf{X})$ es un filtro que altera las propiedades espectrales de la matriz.
2. **Balance:** El rigor matemático debe equilibrarse con la utilidad práctica (Bias-Variance Tradeoff).
3. **Flujo sugerido:** 1. Analizar mecanismo de falta $\rightarrow$ 2. Detectar Outliers (Mahalanobis) $\rightarrow$ 3. Imputar (Multivariado).
4. **Pausa:** Espacio para discusión y preguntas.

$$\text{Spectrum}(\Sigma_{\text{cleaned}}) \approx \text{Spectrum}(\Sigma_{\text{true}}) + \text{Error}_{\text{preprocessing}}$$




Integración de Datos y Concatenación Matricial

1. **Fusión de Repositorios:** Proceso de combinar múltiples fuentes de datos en un esquema unificado.
2. **Representación Algebraica:** Concatenación horizontal de matrices de características X_A y X_B .
3. **Alineación Estricta:** Requisito de resolución de entidades (*Entity Resolution*) para asegurar la correspondencia de filas.
4. **Heterogeneidad Semántica:** Desafío técnico al machear atributos de fuentes dispares.

$$X_{int} = [X_A \mid X_B] \in \mathbb{R}^{n \times (d_1 + d_2)}$$

Sujeto a: $\text{index}(X_A) \equiv \text{index}(X_B)$




El Peligro de la Redundancia: Multicolinealidad Exacta

1. **Redundancia de Atributos:** Ocurre cuando una variable es una función lineal de otra.
2. **Dependencia Lineal:** Un atributo no aporta información ortogonal al sistema.
3. **Impacto en Algoritmos Paramétricos:** 'Veneno' para modelos que asumen independencia de predictores.
4. **Detección:** Uso de tests de correlación para datos numéricos y nominales.

$$\exists \alpha, \beta \mid \mathbf{x}_{d_2} = \alpha \mathbf{x}_{d_1} + \beta$$

$$\text{Matemáticamente: } \sum_{j=1}^d c_j \mathbf{x}_j = \mathbf{0} \text{ para } c_j \neq 0$$



Rango Matricial y Degeneración del Sistema

1. **Rango de una Matriz:** Número máximo de columnas (o filas) linealmente independientes.
2. **Matriz Degenerada (Singular):** Cuando el rango es menor que la dimensionalidad d .
3. **Determinante Cero:** Una matriz con dependencia lineal tiene $\det(A) = 0$.
4. **Invertibilidad:** Solo las matrices de rango completo (no singulares) admiten inversa A^{-1} .

$$\text{rango}(X_{int}) < d_1 + d_2 \implies \det(X_{int}^T X_{int}) = 0$$
$$A \in \mathbb{C}^{n \times n} \text{ es invertible} \iff \text{rango}(A) = n$$




Colapso en la Estimación de Parámetros: El Error Singular

1. **Ecuaciones Normales:** Base de la regresión lineal por mínimos cuadrados (OLS).
2. **Error de Matriz Singular:** Fallo crítico al intentar computar $(X^T X)^{-1}$.
3. **Sistemas Subdeterminados:** Infinitas soluciones posibles cuando la matriz no es de rango completo.
4. **Mala Práctica:** Apilar variables sin análisis previo de dependencia lineal.

$$\theta = (X^T X)^{-1} X^T y$$

$$\text{Si } \det(X^T X) = 0 \implies \nexists (X^T X)^{-1}$$




Multicolinealidad Cercana e Inestabilidad Numérica

1. **Casi-Dependencia:** Variables fuertemente correlacionadas pero no idénticas.
2. **Número de Condición (κ):** Medida de la sensibilidad de la matriz ante pequeñas perturbaciones.
3. **Inestabilidad Espectral:** Pequeños valores de λ_{min} causan que $\kappa \rightarrow \infty$.
4. **Consecuencia:** El ruido ϵ provoca oscilaciones caóticas y masivas en los coeficientes θ .

$$\kappa(A) = \frac{\lambda_{max}}{\lambda_{min}}$$

Si $\lambda_{min} \rightarrow 0 \implies$ Error en θ se amplifica masivamente



Regularización de Tikhonov (Ridge Regression)

1. Acondicionamiento Algebraico:

Inyección de una pequeña constante λ en la diagonal.

2. Garantía de Invertibilidad:

Asegura que todos los autovalores sean estrictamente positivos.


3. Trade-off Sesgo-Varianza:

Sacrificamos un poco de insesgadez por una reducción masiva de la varianza del modelo.

4. Estabilidad:

De-enfatiza características ruidosas y evita coeficientes gigantescos.

$$\boldsymbol{\theta} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$
$$\lambda_{i,new} = \lambda_i + \lambda > 0$$




El Problema de las Escalas Heterogéneas

1. **Dependencia de Unidades:** Los algoritmos basados en distancias (K-Means, KNN) son sensibles a la magnitud.
2. **Dominancia Artificial:** Atributos con rangos grandes (ej. Salario) opacan a los de rango pequeño (ej. Edad).
3. **Métricas Ciegas:** La distancia euclídea no entiende de semántica, solo de magnitudes algebraicas.
4. **Necesidad de Transformación:** Esencial para normalizar el impacto de cada característica.

$$D(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{(\text{Salario}_1 - \text{Salario}_2)^2 + (\text{Edad}_1 - \text{Edad}_2)^2}$$


Si $\Delta \text{Salario} \gg \Delta \text{Edad} \implies \Delta \text{Edad} \approx 0$



Centralización de Datos (Mean Centering)

1. **Ajuste Traslacional:** Mover el origen del sistema de coordenadas al centro de gravedad de los datos.
2. **Notación Matricial:** Uso del vector de unos $\mathbf{1}$ para replicar la media vectorial.
3. **Simplificación:** Facilita el cálculo de la matriz de covarianza como un producto interno.
4. **Pre-requisito para PCA:** Muchos algoritmos de reducción de dimensiones exigen datos centrados.

$$\mu = \frac{1}{n} X^T \mathbf{1}$$
$$Z = X - \mathbf{1} \mu^T$$



Demostración: Propiedad de Media Cero

1. **Invarianza Traslacional:** La estructura de dispersión no cambia al mover los datos en bloque.
2. **Propiedad Algebraica:** La suma de las desviaciones respecto a la media es siempre el vector nulo.
3. **Validación de Algoritmos:** Paso crítico para asegurar que los nuevos ejes en PCA pasen por el centro de la nube de puntos.

$$\mathbb{E}[X - \mu] = \int (x - \mu) f(x) dx = 0$$
$$\frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}) = \frac{1}{n} \left(\sum \mathbf{x}_i - n\boldsymbol{\mu} \right) = \mathbf{0}$$

Rigor Analítico: Demostración de Media Cero


$$\begin{aligned}\bar{\mathbf{z}} &= \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}) \\ &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i - \frac{1}{n} \sum_{i=1}^n \boldsymbol{\mu} \\ &= \boldsymbol{\mu} - \frac{n\boldsymbol{\mu}}{n} \\ &= \mathbf{0}\end{aligned}$$

El nuevo centro de gravedad probabilístico del espacio transformado Z es rigurosamente el vector nulo.

Escalamiento Min-Max (Normalización)

1. **Rango Acotado:** Transforma los datos al intervalo cerrado (o $[-1, 1]$).
2. **Preservación de Distribución:** Mantiene la forma original pero cambia la escala.
3. **Sensibilidad a Outliers:** Un solo valor extremo comprimirá toda la masa de datos en un rango minúsculo (casi 0).
4. **Uso Común:** Redes neuronales y algoritmos que requieren valores en el rango de funciones de activación.

$$x'_{ij} = \frac{x_{ij} - \min(X_j)}{\max(X_j) - \min(X_j)}$$



Estandarización Estadística (Z-Score)

- 1. Unidades de Sigma:** Escalamiento basado en la desviación estándar.
- 2. Propiedades:** Media resultante $\mu = 0$ y varianza unitaria $\sigma^2 = 1$.
- 3. Pearson:** La covarianza de dos variables estandarizadas es igual a su coeficiente de correlación de Pearson.
- 4. Ventaja:** Menos sensible a outliers que el Min-Max, asumiendo una distribución unimodal.

$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

$$\text{Cov}(X'_j, X'_k) = \text{Corr}(X_j, X_k)$$

Isotropía Probabilística: Estandarización (Z-Score)



El Duelo de las Escalas

Min-Max	Z-Score
• Límites Fijos Estrictos • Geometría Rígida • Frágil ante Outliers	• Límites Infinitos • Varianza Unitaria (Isotropía) • Resiliente a Outliers

Relación de Pearson:


$$r_{xy} = \frac{1}{n-1} \mathbf{z}_x^T \mathbf{z}_y$$

Transformaciones Lineales y Estructura de Covarianza

1. **Mapeo de Varianza:** Cómo cambia la dispersión tras una rotación o escalamiento.
2. **Ecuación Clave:** La covarianza de la transformación es el producto de la matriz de pesos y la covarianza original.
3. **Fundamento de PCA:** Permite encontrar una matriz W tal que la nueva covarianza Σ_Y sea diagonal (independiente).

$$\text{Si } \mathbf{y} = W^T \mathbf{x} \implies \Sigma_Y = W^T \Sigma_X W$$
$$\mathbb{E}[(W^T X)(W^T X)^T] = W^T \mathbb{E}[XX^T] W$$

**El Efecto en la Variabilidad:
Transformación de la Covarianza**



$$\text{Si } Y = XW \Rightarrow \Sigma_Y = W^T \Sigma_X W$$

Con Estandarización, la matriz de covarianza Σ_Z se convierte en la Matriz de Correlación. Hemos estabilizado todas las orientaciones del espacio hiperdimensional.

Preprocesamiento y Convergencia del Gradiente


1. **Topología del Error:** El escalamiento afecta la forma de las curvas de nivel de la función de pérdida.
2. **El 'Cañón Elongado':** Sin estandarización, el gradiente oscila ineficientemente en ejes de distinta escala.
3. **Acondicionamiento del Hessiano:** Estandarizar baja el número de condición κ de la matriz de segundas derivadas.
4. **Velocidad:** Curvas más circulares permiten pasos de aprendizaje más grandes y convergencia rápida.

$$\Delta \theta = -\eta \nabla J(\theta)$$


$$\text{Estandarización} \implies \kappa(\nabla^2 J) \approx 1 \text{ (Esfera)}$$

Topología del Aprendizaje: El Acondicionamiento del Hessiano

Data Cruda: Mal Acondicionamiento



Data Estandarizada: Isotropía



$$\text{Paso de Actualización: } \theta_{t+1} = \theta_t - \eta \nabla J(\theta)$$

$$\text{Condición del Hessiano: } \kappa(H) = \frac{\lambda_{\max}(H)}{\lambda_{\min}(H)} \approx 1 \text{ (Ideal)}$$

La Regla de Oro: Evitando el Data Leakage

1. **Aislamiento de Información:** Las métricas de preprocesamiento (μ , σ , *max*) se calculan **SOLO** en el conjunto de entrenamiento.
2. **Fuga de Datos (Leakage):** Usar información del conjunto de Test para normalizar el Train invalida la evaluación.
3. **El Error #1:** Causa modelos que parecen perfectos en el laboratorio pero fallan catastróficamente en producción.
4. **Protocolo:** *Fit* en Train $\rightarrow$ *Transform* en Train $\rightarrow$ *Transform* en Test.

$$\mu_{train} = \text{mean}(X_{train}) \quad ; \quad X'_{test} = \frac{X_{test} - \mu_{train}}{\sigma_{train}}$$



Repensando la Distancia Euclídea: El Supuesto Isótropo


1. **Métrica por Defecto:** Distancia de "línea recta" o "vuelo de pájaro" entre puntos en $\mathbb{R}^d$.
2. **Axioma Oculto:** Asume que el espacio es **isótropo** y las dimensiones son ortonormales (I).
3. **Limitación Estadística:** Ignora por completo la estructura de covarianza entre atributos.
4. **Inestabilidad de Escala:** Altamente sensible a las unidades de medida si no hay normalización previa.

$$D_E(\mathbf{x}, \mu) = \sqrt{(\mathbf{x} - \mu)^T \mathbf{I} (\mathbf{x} - \mu)}$$

Donde $\mathbf{I} = \text{diag}(1, 1, \dots, 1) \implies$ Covarianzas asumidas nulas

El Espejismo Euclidiano: La Falacia del Espacio Isótropo

Supuesto Fundamental: La métrica L2 asume un espacio ortogonal e isótropo.



$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^T (\mathbf{x} - \mathbf{y})}$$

El Defecto: Al evaluar distancias, la métrica Euclidiana trata la matriz de covarianza como una matriz identidad (I). Ignora sistemáticamente la correlación multivariada.



Consecuencia Analítica: Dos vectores pueden poseer idéntica norma L2 respecto al centroide, pero probabilidades marginales radicalmente opuestas.

En espacios de alta dimensionalidad, medir sin considerar la covarianza es equivalente a navegar un terreno montañoso asumiendo que es plano.

Mahalanobis a Profundidad: Rotación y Blanqueamiento

1. Distancia Estadística:

Generalización que escala el espacio según Σ .

2. Invariancia: Es independiente de la escala y considera la correlación lineal.

3. Mecanismo Dual:

1. Rotación de ejes hacia componentes principales (PCA).
2. Escalamiento de cada eje por su desviación estándar ($1/\sigma$).

4. Equivalencia: Si $\Sigma=I$, Mahalanobis colapsa en la métrica Euclídea.


$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})}$$

Transformación de Blanqueamiento (Whitening): $\mathbf{z} = \Lambda^{-1/2} \mathbf{U}^T (\mathbf{x} - \boldsymbol{\mu})$

Definición Formal: $D_M(\mathbf{x}, \boldsymbol{\mu}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})}$


El Factor Correctivo: La matriz inversa Σ^{-1} es un operador lineal que rota el hiperplano hacia sus componentes principales y divide la varianza.

1. Datos Crudos




Matriz de Covarianza Original Σ

2. Rotación (PCA)



Descomposición Espectral ($\Sigma = P\Lambda P^T$)

3. Escalamiento (Whitening)



Blanqueamiento Espacial (Σ^{-1})

Axioma de Equivalencia: La métrica de Mahalanobis es estrictamente equivalente a la distancia Euclídea calculada después de descorrelacionar y aplicar varianza unitaria.

El Pipeline KDD Riguroso: Flujo de Integridad

1. **Fase 1: Integración:** Control estricto del rango matricial para evitar singularidad.
2. **Fase 2: Limpieza:** Mitigación del colapso de covarianza tras imputaciones.
3. **Fase 3: Transformación:** Transición de Σ a la matriz de correlación R vía estandarización.
4. **Fase 4: Outliers:** Aplicación de D_M sobre el espacio transformado para purgar ruidos.
5. **Resultado:** Datos condicionados listos para algoritmos de alta capacidad.

$$\mathbf{X}_{raw} \xrightarrow{\text{Clean}} \mathbf{X}_{imp} \xrightarrow{\text{Standardize}} \mathbf{Z} \xrightarrow{D_M} \text{Knowledge}$$

Goal: $\text{cond}(\mathbf{Z}^T \mathbf{Z}) \rightarrow 1$



Conclusión: El Preprocesamiento como Techo de Rendimiento

1. **Determinismo de Calidad:** "Garbage In, Garbage Out".
2. **Límite Superior:** El preprocesamiento define el techo de precisión del modelo.
3. **Fatalidad Algebraica:** Ninguna red neuronal profunda puede extraer información de una matriz singular o dependiente.
4. **Rigor Final:** La maestría en ML reside en la ingeniería del espacio métrico, no solo en la arquitectura del modelo.

$$\text{Acc}_{\text{model}} \leq \text{Quality}(\mathcal{T}(D))$$

Si $\text{rank}(X) < d \implies$ Información perdida irre recuperable

El Teorema Práctico del Modelado de Datos

El rigor del preprocesamiento define el límite superior de rendimiento de cualquier modelo predictivo.

Ninguna red neuronal profunda, por masiva o compleja que sea su arquitectura, tiene la capacidad matemática para curar una **Matriz Singular** ($\det(\Sigma) = 0$) ni generar información a partir de un colapso estadístico previo.

El algoritmo modela el mundo exacto que le presentamos. Si la topología del espacio de entrada es defectuosa, la inferencia será algorítmicamente perfecta, pero lógicamente inútil.

Bibliografía General

- Aggarwal, C. C. (2015). Data Mining: The Textbook. Springer. Esta obra proporciona el marco teórico para la regularización de Ridge, el análisis de outliers y el tratamiento de la varianza en modelos de alta dimensionalidad.
- ElAtia, S., Ipperciel, D., & Zaïane, O. R. (Eds.). (2016). Data Mining and Learning Analytics: Applications in Educational Research. John Wiley & Sons, Inc. Este texto fundamenta las aplicaciones prácticas de minería de procesos educativos y el uso de Moodle como fuente de datos.
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From Data Mining to Knowledge Discovery in Databases. AI Magazine, 17(3), 37–54. Es el artículo fundacional que define el pipeline KDD riguroso utilizado en la estructura de la presentación.
- Google. (2026). NotebookLM: Generador de diapositivas e imágenes sintéticas mediante inteligencia artificial [Software]. Google Research. Esta herramienta actuó como el motor de síntesis de contenidos, diseño instruccional y generación de los elementos visuales presentados en las diapositivas.
- Han, J., Kamber, M., & Pei, J. (2012). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann. Fuente principal para la taxonomía de atributos, el modelado de ruido gaussiano y las etapas de integración de datos.

Bibliografía General

- Navarro, L. A. (2025). Minería de Datos: Introducción + Análisis de Componentes Principales [Apuntes de clase]. Escuela Profesional de Ciencia de la Computación, Universidad Nacional de Ingeniería. Este material estructuró los objetivos específicos y el enfoque algebraico del curso.
- Simovici, D. A., & Djeraba, C. (2014). Mathematical Tools for Data Mining: Set Theory, Partial Orders, Combinatorics. Springer. Proporciona el soporte matemático para el análisis de rango matricial, determinantes y singularidad de matrices.
- Tan, P.-N., Steinbach, M., & Kumar, V. (2018). Introduction to Data Mining (2nd ed.). Pearson. Texto clave para la explicación de las métricas de distancia (Euclídea vs. Mahalanobis) y la normalización Min-Max.
- Witten, I. H., Frank, E., & Hall, M. A. (2011). Data Mining: Practical Machine Learning Tools and Techniques (3rd ed.). Morgan Kaufmann. Utilizado para la formalización del riesgo empírico, funciones de pérdida y la implementación práctica del preprocesamiento.
- Zaki, M. J., & Meira Jr., W. (2014). Data Mining and Analysis: Fundamental Concepts and Algorithms. Cambridge University Press. Aporta la profundidad geométrica sobre el blanqueamiento de datos y la centralización de matrices.

Notas sobre la generación de contenidos

- Las **imágenes** y la **síntesis algorítmica** de las fórmulas matemáticas en LaTeX fueron procesadas por **NotebookLM** basándose exclusivamente en los textos fuente citados, asegurando que cada representación visual sea semánticamente consistente con los teoremas de minería de datos.