



UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ciencias

Escuela Profesional de Ciencia de la Computación

SÍLABO

1. INFORMACIÓN GENERAL

Curso	:	Minería de Datos
Código	:	CC442
Pre-requisito	:	Inteligencia Artificial
Dpto. Académico	:	Ciencia de la Computación
Condición	:	Obligatorio
Ciclo Académico	:	2026-I
Créditos	:	04 (cuatro)
Horas teóricas	:	2 horas semanales
Horas practicas	:	4 horas semanales
Sistema de evaluación	:	G

2. SUMILLA

El curso de Minería de Datos proporciona una base sólida en el proceso de descubrimiento de conocimiento en bases de datos (Knowledge Discovery in Databases - KDD). Se centra en la extracción de patrones no triviales, implícitos y previamente desconocidos a partir de grandes volúmenes de datos. El curso cubre desde el preprocesamiento de datos hasta técnicas avanzadas de clasificación, clustering, minería de reglas de asociación y minería de datos complejos (texto, redes). Se enfatiza tanto el rigor matemático de los algoritmos como su implementación práctica en entornos de computación en la nube.

3. OBJETIVOS DEL CURSO

- Comprender y aplicar el proceso completo de minería de datos bajo estándares internacionales.
- Desarrollar la capacidad de derivar matemáticamente y programar algoritmos fundamentales de minería de datos.
- Evaluar críticamente modelos de aprendizaje supervisado y no supervisado utilizando métricas de rendimiento adecuadas.
- Resolver problemas complejos de negocio o investigación mediante el análisis de datos reales.

4. RESULTADOS DE APRENDIZAJE

Al finalizar el curso, el estudiante podrá:

- Diseñar e implementar pipelines de preprocesamiento de datos (limpieza, integración, transformación y reducción).
- Derivar matemáticamente y optimizar algoritmos de aprendizaje supervisado y no supervisado.
- Analizar críticamente el estado del arte a través de papers científicos.
- Ejecutar proyectos aplicados con datasets reales bajo estándares de conferencias técnicas.

5. COMPETENCIAS

- **Detección e Interpretación:** Capacidad para la detección, interpretación y predicción de patrones cuantitativos y cualitativos en los datos.

- **Extracción de Conocimiento:** Dominio del proceso de extraer información o patrones interesantes (no triviales, implícitos, previamente desconocidos y potencialmente útiles) desde grandes repositorios.
- **Fundamentación Teórica:** Comprender los conocimientos de bases de datos y los principios de la ciencia de la computación aplicados al análisis de datos masivos.
- **Toma de Decisiones Técnicas:** Capacidad de decidir ante un problema práctico concreto qué tarea de minería de datos conviene utilizar, qué modelo se quiere obtener, qué técnica resultaría más adecuada y cómo evaluar los resultados obtenidos de manera rigurosa.

6. CONOCIMIENTOS PREVIOS RECOMENDADOS

- Inteligencia Artificial (Prerrequisito formal).
- Probabilidad y Estadística.
- Álgebra Lineal y Cálculo Multivariable.
- Programación avanzada en Python.

7. CONTENIDOS ORGANIZADOS POR UNIDADES

- **Unidad I:** Fundamentos y Preparación de Datos (Semanas 1-3)
 - CAPÍTULO 1: Introducción a la Minería de Datos. Tecnologías relacionadas: Aprendizaje automático, DBMS, OLAP, Estadísticas. Objetivos y etapas del proceso de minería de datos (KDD, CRISP-DM). Técnicas y métodos de representación del conocimiento.
 - CAPÍTULO 2: Exploración y Preprocesamiento. Atributos y tipos de datos. Calidad de datos. Limpieza, integración, transformación y reducción de datos. Discretización y jerarquías de conceptos.
- **Unidad II:** Patrones Frecuentes y Asociaciones (Semanas 4-5)
 - CAPÍTULO 3: Minería de Reglas de Asociación. Conceptos básicos: soporte y confianza. Algoritmo Apriori. Mejora de la eficiencia. Algoritmo FP-Growth para minería de patrones frecuentes sin generación de candidatos. Evaluación de reglas de asociación.
- **Unidad III:** Clasificación y Predicción (Semanas 6-9)
 - CAPÍTULO 4: Clasificación y Modelado Estocástico. Inducción de árboles de decisión (ID3, C4.5). Clasificación Bayesiana y Redes Bayesianas. Máquinas de Soporte Vectorial (SVM). Redes Neuronales y Deep Learning aplicado.
 - CAPÍTULO 5: Evaluación de Clasificadores. Métricas de desempeño (Precisión, Recall, F1, AUC-ROC). Métodos de validación (Hold-out, Cross-validation, Bootstrap).
- **Unidad IV:** Análisis de Agrupamiento - Clustering (Semanas 10-12)
 - CAPÍTULO 6: Métodos de Clustering. Tipos de datos en el análisis de clusters. Métodos de partición (K-means, K-medoids). Métodos jerárquicos (Agglomerative, Divisive). Clustering basado en densidad (DBSCAN, OPTICS). Clustering basado en modelos y cuadrículas.
- **Unidad V:** Minería de Datos Complejos y Aplicaciones (Semanas 13-14)
 - CAPÍTULO 7: Tópicos Avanzados. Minería de texto y procesamiento de lenguaje natural. Minería de grafos y redes sociales. Sistemas de recomendación (filtrado colaborativo). Tendencias actuales en minería de datos e IA.

8. PLANIFICACIÓN SEMANAL

Sem	Tema de Teoría	Actividad de Laboratorio	Lectura Recomendada	Evaluación / Entregable
1	Introducción al Proceso KDD y Tipos de Datos. Cap 1: Conceptos básicos y etapas.	Configuración de entorno en Google Colab y Python (Numpy/Pandas) Review.	Han Cap. 1-2	–
2	Preprocesamiento: Limpieza, Integración y Transformación. Calidad de datos.	Análisis Exploratorio de Datos (EDA) profundo con visualización.	Tan Cap. 2	–
3	Reducción de Dimensionalidad: Matemática de PCA y SVD.	Implementación de PCA desde cero vs scikit-learn.	Bishop Cap. 12	PC1
4	Reglas de Asociación: Algoritmo Apriori y métricas de evaluación.	Minería de transacciones comerciales (Market Basket Analysis).	Aggarwal Cap. 4	–
5	Patrones Frecuentes: FP-Growth y optimización de candidatos.	Comparativa de eficiencia: Apriori vs FP-Growth.	Han Cap. 6	–
6	Clasificación I: Árboles de Decisión (ID3, C4.5) e Information Gain.	Construcción, poda y visualización de árboles de decisión.	Tan Cap. 4	PC2
7	Clasificación II: SVM y Kernel Trick (Derivación matemática).	Optimización de hiperparámetros y Cross-validation.	Bishop Cap. 7	Propuesta de Proyecto
8	EXAMEN PARCIAL (EP)		<i>Suspensión de actividades lectivas</i>	
9	Clasificación III: Ensamble Learning (Random Forest, Boosting).	Kaggle Mini-challenge: Clasificación de Fraude Financiero.	Hastie Cap. 10	–
10	Clustering I: Métodos Particionales (K-means, K-medoids).	Implementación y métricas de validación (Silhouette, Elbow).	Han Cap. 10	PC3
11	Clustering II: Basado en Densidad (DBSCAN) y GMM.	Detección de anomalías en datos espaciales y ruidosos.	Aggarwal Cap. 15	–
12	Minería de Texto: TF-IDF y Word Embeddings básicos.	Análisis de sentimientos con datos reales de redes sociales.	Leskovec Cap. 1	–
13	Sistemas de Recomendación: Filtro Colaborativo y Content-based.	Construcción de un motor de recomendación híbrido.	Aggarwal Cap. 18	PC4
14	Minería de Grafos: Algoritmo PageRank y Centralidad.	Análisis de comunidades en redes con NetworkX.	Leskovec Cap. 10	Borrador de Paper
15	EXPOSICIÓN DE PROYECTOS FINALES (PF)		<i>Presentación técnica y entrega de Paper</i>	
16	EXAMEN FINAL (EF)		<i>Evaluación acumulativa teórica</i>	

9. USO DE HERRAMIENTAS TECNOLÓGICAS

- **Google Colab:** Entorno principal para asegurar reproducibilidad.
- **GitHub:** Control de versiones para el proyecto final.
- **LaTeX (Overleaf):** Para la redacción del paper técnico final.

10. SISTEMA DE EVALUACIÓN

La nota final se calcula mediante la siguiente fórmula:

$$PromedioFinal = \frac{EP + EF + PP}{3} \quad (1)$$

Donde el Promedio de Prácticas (PP) incluye las tres mejores notas de las prácticas calificadas (PC) y el Proyecto Final (PF):

$$PP = \frac{Mejores\ 3\ de\{PC_1 + PC_2 + PC_3 + PC_4\} + PF}{4} \quad (2)$$

11. PROYECTO FINAL

Consiste en un trabajo aplicado con un dataset real. Los entregables incluyen:

- Implementación funcional en Python/Colab.
- Paper técnico corto (estilo IEEE/ACM).
- Presentación de resultados.

12. POLÍTICAS DEL CURSO

- **Honestidad Académica:** El uso de herramientas de IA generativa está permitido para asistencia en código, pero no para la redacción total del paper. Todo uso debe ser declarado.
- **Puntualidad:** Los entregables de laboratorio tienen una penalización del 10 % por cada hora de retraso.

13. BIBLIOGRAFÍA BÁSICA

- Han, J., Kamber, M., & Pei, J. *Data Mining: Concepts and Techniques*.
- Tan, P. N., Steinbach, M., & Kumar, V. (2018). *Introduction to Data Mining*. Pearson.
- Bishop, C. *Pattern Recognition and Machine Learning*.
- Aggarwal, C. C. *Data Mining: The Textbook*.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- Leskovec, J., Rajaraman, A., & Ullman, J. D. (2020). *Mining of Massive Datasets*. Cambridge University Press.