

Curso de Minería de Datos CC442

Clase 1

Prof. Marcos Alania

Programa del día

I. Presentación

II. Calendario y Sílabo del Curso

III. Libros y links de interés

IV. Sistema de Evaluación

- Proyecto del curso
- Formación de grupos


V. Acreditación ABET

- Nombramiento de Delegado y subdelegado
- Prueba de entrada

VI. Inicio de los tópicos del Curso

Minería de Datos: Conceptos y Técnicas

Introducción al Proceso de Descubrimiento de Conocimiento (KDD) y Fundamentos Geométricos de los Datos.



[CS_Nivel_Superior] Basado en Han, Kamber & Pei

Historia: Línea de tiempo

- **1980s:** Primeras menciones de *data mining* en estadística aplicada y sistemas de bases de datos.
 - Hand, D. J. (1981). *Discrimination and Classification*. Chichester: Wiley.
- **1989:** Primer *Workshop on Knowledge Discovery in Databases* (AAAI, Detroit).
 - Piatetsky-Shapiro, G. (1991). *Knowledge Discovery in Real Databases: A Report on the IJCAI-89 Workshop*. *AI Magazine*, 11⑤, 68–70.
- **1995:** Primera conferencia internacional KDD en Montreal.
 - Fayyad, U., & Uthurusamy, R. (Eds.). (1995). *Proceedings of the First International Conference on Knowledge Discovery and Data Mining*. Montreal: AAAI Press.
- **1996:** Publicación seminal.
 - Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, 17③, 37–54.
<https://doi.org/10.1609/aimag.v17i3.1230> (doi.org in Bing)

Historia: Línea de tiempo

- **2000s:** Expansión hacia ICDM (IEEE), PKDD (Europa), ECML (Machine Learning).
 - Han, J., & Kamber, M. (2001). *Data Mining: Concepts and Techniques*. San Francisco: Morgan Kaufmann.
- **2005:** Consolidación del campo.
 - Maimon, O., & Rokach, L. (Eds.). (2005). *Data Mining and Knowledge Discovery Handbook*. New York: Springer.
- **2010s:** Integración con *Big Data* y *Data Science*.
 - Provost, F., & Fawcett, T. (2013). *Data Science for Business*. Sebastopol: O'Reilly Media.
- **2020s:** KDD se integra con IA explicable y ética de datos.
 - Baeza-Yates, R. (2020). Bias on the Web. *Communications of the ACM*, 63(6), 54–61. <https://doi.org/10.1145/3390881>

Historia: Primeras conferencias KDD

- **1989:** AAAI Workshop on KDD.
 - Piatetsky-Shapiro, G. (1991). *Knowledge Discovery in Real Databases: A Report on the IJCAI-89 Workshop*. *AI Magazine*, 11⑤, 68–70.
- **1995:** Primera conferencia internacional KDD en Montreal.
 - Fayyad, U., & Uthurusamy, R. (Eds.). (1995). *Proceedings of the First International Conference on Knowledge Discovery and Data Mining*. Montreal: AAAI Press.
- **1997 en adelante:** KDD anual, expansión global.
 - ACM SIGKDD. (1997–2025). *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM.

Historia: Comparación conceptual temprana

- **Data Mining:** Técnicas algorítmicas para extraer patrones.
 - Han, J., & Kamber, M. (2001). *Data Mining: Concepts and Techniques*. San Francisco: Morgan Kaufmann.
- **KDD:** Proceso completo (selección, preprocesamiento, minería, interpretación).
 - Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, 17^③, 37–54.
- **Machine Learning:** Enfoque en modelos predictivos y clasificación.
 - Mitchell, T. M. (1997). *Machine Learning*. New York: McGraw-Hill.
- **Estadística clásica:** Inferencia sobre muestras, énfasis en significancia.
 - Cox, D. R. (1970). *The Analysis of Binary Data*. London: Chapman & Hall.

Historia: Evolución del concepto de “Tipos de Datos”

- **Iniciales (1980s-90s):** Datos relacionales, transacciones bancarias, registros científicos.
 - Agrawal, R., Imieliński, T., & Swami, A. (1993). Mining Association Rules between Sets of Items in Large Databases. *ACM SIGMOD Record*, 22②, 207–216.
- **Posteriores (2000s):** Texto, imágenes, datos web, series temporales.
 - Feldman, R., & Sanger, J. (2007). *The Text Mining Handbook*. Cambridge: Cambridge University Press.
- **Actualidad (2010s-2020s):** Big Data, redes sociales, datos no estructurados.
 - Chen, M., Mao, S., & Liu, Y. (2014). Big Data: A Survey. *Mobile Networks and Applications*, 19②, 171–209. <https://doi.org/10.1007/s11036-013-0489-0> (doi.org in Bing)

Historia: Raíces Interdisciplinarias del DM



Estadística

- ✓ Teoría de probabilidad
- ✓ Estimación y cuantificación
- ✓ Incertidumbre y rigor matemático



Bases de Datos

- ✓ Optimización de consultas
- ✓ Sistemas transaccionales
- ✓ Eficiencia y escalabilidad



Inteligencia Artificial

- ✓ Reconocimiento de patrones
- ✓ Aprendizaje automático
- ✓ Algoritmos heurísticos

80s

Limitaciones de Sistemas Expertos

Reglas manuales insuficientes para dominios complejos

90s

Nacimiento de Data Mining

Primeros algoritmos de reglas de asociación (Apriori)

Evolución Disciplinaria: De BD y Estadística a DM



Impacto Real: Aplicaciones Transformadoras




Meteorología

Predicción de anomalías extremas

Correlación histórica de miles de sensores interdependientes para alertas tempranas


Real time credit card fraud detection



Finanzas

Detección de fraude en milisegundos

Análisis de grafos de transacciones para identificar patrones sospechosos



Bioinformática

Descubrimiento genético

Identificación de secuencias genéticas asociadas a enfermedades específicas




Recomendación

Filtrado colaborativo

Personalización de contenido en plataformas de streaming masivo

El Pipeline KDD: Un Proceso Iterativo

Proceso de Descubrimiento de Conocimiento en Bases de Datos (KDD)



Formalización de las Etapas: Qué Sucede Realmente



Resolviendo la Confusión: KDD vs Data Mining

Knowledge Discovery in Databases (KDD)

Preparación
de Datos

Data Mining
(El motor algorítmico)

Validación y
Despliegue


KDD:

El oleoducto macro. Proceso iterativo impulsado por expertos en el dominio.

Data Mining:

La cámara de combustión.
El paso matemático de modelado.

KDD en Acción: Predicción de Deserción Estudiantil



Inferencia vs Predicción: Dos Paradigmas

Inferencia

¿Por qué ocurre?



Entender el mecanismo

Comprender el modelo generador subyacente



Relaciones causales

Identificar causas y efectos directos



Ejemplo en clima

¿Cómo afecta un aumento de 10 hPa de presión a la probabilidad de lluvia?

Predicción

¿Qué ocurrirá?



Precisión empírica

Alta exactitud en resultados prácticos



Caja negra

Modelos sin interpretación causal directa



Ejemplo en clima

Dadas las lecturas actuales, ¿lloverá mañana con alta probabilidad?

Data Mining: El Motor de Inferencia

Paso esencial donde se aplican **métodos inteligentes** para extraer patrones



Reconocimiento de Patrones

- ✓ Identificar estructuras
- ✓ Descubrir regularidades
- ✓ Detectar anomalías



Aprendizaje Automático

- ✓ Algoritmos que mejoran
- ✓ Experiencia empírica
- ✓ Optimización automática




Modelamiento Estadístico

- ✓ Cuantificar incertidumbre
- ✓ Validar hallazgos
- ✓ Intervalos de confianza

Taxonomía de los Datos



Tecnologías Integradas



Para que este núcleo interdisciplinario funcione de manera automatizada, primero debemos matematizar nuestra realidad...

(La Anatomía Computacional)

No hay descubrimiento de patrones sin una representación formal de los objetos y los objetos y sus dimensiones matemáticas.

No hay descubrimiento de patrones sin una representación formal de los objetos y los objetos y sus dimensiones matemáticas.

representación formal de los objetos y los objetos y sus dimensiones matemáticas.

Abstracción Fundamental: Traducir la Realidad al Algebra




Un conjunto de datos estándar se abstrae como una matriz $X \in \mathbb{R}^{n \times d}$

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{pmatrix}$$

n : Número de instancias (observaciones, registros del mundo real).

d : Número de **dimensiones** (atributos, variables medidas).

Anatomía Numérica: Objetos y atributos



Objeto (Fila):

También llamado instancia, registro o tupla. Matemáticamente, tratamos al objeto i como un vector columna en $\mathbb{R}^d$:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})^T$$

Atributo (Columna):

También llamado dimensión o feature. Describe una propiedad medible del objeto a través de todas las instancias.

El Gran Reto Moderno: El 80% de la data mundial es No Estructurada (texto libre, imágenes, secuencias de ADN). Debe transformarse obligatoriamente a esta forma vectorial $\mathbf{x}_i$ para operar matemáticamente.


Taxonomía de los Datos: Escalas de Medición

Tipo de Atributo	Naturaleza	Operaciones Matemáticas	Ejemplo
Nominal	Categorías sin orden	$=, \neq$	Color, ID de paciente
Binario	Simétrico / Asimétrico	Lógica Booleana (0, 1)	Fuma/No fuma, Test Médico
Ordinal	Orden implícito, magnitud desconocida	$<, >$	Tallas de ropa, Rangos militares
Numérico	Cantidades exactas (Intervalo/Razón)	$+, -, \times, \div$	Temperatura, Salario



La riqueza de las operaciones matemáticas permitidas aumenta al descender por la matriz, definiendo qué algoritmos pueden aplicarse.

Centro de Gravedad Dimensional: La Media Vectorial




- En problemas supervisados, extendemos la matriz $X \in \mathbb{R}^{n \times d}$ con un vector de etiquetas $y \in \mathbb{R}^n$.
- El primer paso analítico es encontrar el centro geométrico de nuestro espacio X .


En d dimensiones, la media no es un escalar, es un Vector Media $\mu \in \mathbb{R}^d$:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_d \end{pmatrix}$$

Descripción Estadística - Tendencia Central



Midiendo la Dispersión: La Matriz de Covarianza



¿Cómo varían los datos alrededor de μ ?
Encapsulamos todas las relaciones entre atributos en la Matriz de Covarianza Σ .

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$$

Anatomía de Σ

- Es una matriz cuadrada de $d \times d$.
- **La Diagonal:** Contiene las varianzas individuales de cada atributo.
- **Fuera de la Diagonal:** Mide cómo dos dimensiones covarían (cambian juntas).


Descripción Estadística - Dispersión

Rango = max - min


IQR = Q3 - Q1

Varianza: $\sigma^2 = \frac{1}{N} \sum (x_i - \bar{x})^2$

El Rango Intercuartil (IQR) aísla matemáticamente el ruido de los patrones estructurales centrales.



El Aprendizaje Supervisado y la Función de Pérdida



El **Objetivo**: Encontrar una función f dentro de un Espacio de Hipótesis $\mathcal{H}$ que mapee $x_i \rightarrow y_i$.


Función de Pérdida $L(f(x_i), y_i)$: Penaliza matemáticamente la diferencia entre la predicción y la realidad.

El **Riesgo Empírico** (R_{emp}): Mide el error promedio de nuestra función sobre los datos de entrenamiento que poseemos:


$$R_{emp}(f) = \frac{1}{n} \sum_{i=1}^n L(f(x_i), y_i)$$

Minimización y el Fantasma del Sobreajuste (Overfitting)

Generalización



Sobreajuste (Overfitting)




Optimización: Buscamos la función óptima f^* que minimice el riesgo:

$$f^* = \operatorname{argmin}_{f \in \mathcal{H}} R_{emp}(f)$$

El Problema Práctico: Si minimizamos R_{emp} a exactamente 0, la función memoriza el ruido del pasado, perdiendo su capacidad de generalizar.

Riesgo Esperado (Mundo Real) vs. Riesgo Empírico (Entrenamiento). El éxito no es predecir el pasado, es generalizar al futuro.

Distancia de Minkowski




$$d(i, j) = \sqrt[h]{|x_{i1} - x_{j1}|^h + \dots + |x_{ip} - x_{jp}|^h}$$

Minkowski es el formalismo generalizado; ajustar el parámetro h altera fundamentalmente la topología del espacio de búsqueda.

Medidas de Proximidad (Similitud y Disimilitud)


Similitud de Coseno (Para Datos Dispersos / Text Mining)



$$\text{sim}(x, y) = \frac{x \cdot y}{|x| |y|}$$

Evalúa el ángulo de orientación entre dos entidades vectoriales independientemente de su magnitud matemática. Si dos documentos usan las mismas palabras, apuntan en la misma dirección, sin importar si uno tiene 10 páginas y el otro 1000.

El Motor del Descubrimiento



Los algoritmos carecen de intuición. No pueden encontrar patrones, agrupar objetos ni detectar anomalías sin una definición matemática estricta de proximidad y similitud.

La geometría de los datos ES la lógica de la minería.

La Geometría del Conocimiento

01.

El valor reside en el sistema **KDD**, no en el volumen: Generar **petabytes** es inevitable; transformar esa densidad mediante las **7 etapas iterativas** es lo único que genera ventaja competitiva.

02.

Basura entra, basura sale (**GIGO**): La calidad deductiva de la **Minería de Datos** es proporcional al rigor de la **limpieza estadística previa** (medias, varianzas, IQR).

03.

La métrica dicta la realidad: Elegir entre la **distancia de Minkowski** y la **Similitud de Coseno** no es un detalle técnico; es la decisión que define cómo tu algoritmo interpreta la **estructura del universo de datos**.