

CC442: Tarea Académica de la Primera Práctica Calificada

Condicionamiento Espectral y Estabilidad Numérica en el Preprocesamiento

1. Introducción y Motivación Matemática

En la teoría del aprendizaje estadístico, el preprocesamiento de datos no debe ser entendido como una mera limpieza empírica, sino como la aplicación de un **operador de transformación lineal o no lineal** que actúa sobre el espectro de la matriz de datos $\mathbf{X} \in \mathbb{R}^{n \times d}$.

La convergencia de algoritmos de optimización (como el descenso de gradiente) y la estabilidad de estimadores paramétricos dependen críticamente del *número de condición* $\kappa(\mathbf{X}^T \mathbf{X}) = \frac{\lambda_{max}}{\lambda_{min}}$. Un dataset mal condicionado introduce inestabilidad numérica que amplifica el ruido de medición ϵ , degradando la capacidad de generalización del modelo posterior. Esta tarea exige que el estudiante actúe como un ingeniero de espacios métricos, asegurando que la matriz de características resultante sea óptima desde una perspectiva algebraica y probabilística.

2. Objetivos Formativos

- Analizar la estructura espectral de la matriz de datos y su impacto en la estabilidad numérica.
- Modelar formalmente el ruido y los mecanismos de ausencia de datos (MCAR, MAR, MNAR).
- Demostrar matemáticamente la distorsión introducida por los operadores de limpieza e imputación.
- Garantizar la invarianza traslacional y el blanqueamiento espectral mediante transformaciones lineales.

3. Datasets Académicos Seleccionados

Cada estudiante será asignado de forma individual a uno de los siguientes repositorios académicos (orientados a clasificación binaria o multiclase con retos de integridad):

1. **Arrhythmia (UCI)**: 279 atributos, alta tasa de missing values y clases desbalanceadas.
2. **Pima Indians Diabetes**: Problema de ruido gaussiano y escalas heterogéneas.
3. **Ionosphere (UCI)**: Atributos complejos en el dominio real con redundancia lineal.
4. **Heart Disease (Cleveland/Hungarian)**: Reto de integración de fuentes y datos MNAR.
5. **Hepatitis**: Dataset pequeño con alto ratio de valores faltantes por registro.

6. **Breast Cancer Wisconsin (Diagnostic):** Multicolinealidad extrema entre características geométricas.
7. **Sonar:** Reto de alta dimensionalidad con escalas idénticas pero correlación fuerte.
8. **Spambase:** Escalas heterogéneas (frecuencias vs. longitudes) y outliers severos.

4. Actividades Obligatorias

4.1. A) Análisis Estructural Inicial

Defina su dataset como una matriz $\mathbf{D} \in \mathbb{R}^{n \times d}$. Calcule y discuta:

1. El rango matricial $\text{rank}(\mathbf{D})$. ¿Es la matriz de rango completo?
2. El número de condición $\kappa(\mathbf{X}^T \mathbf{X})$. Evalúe el riesgo de singularidad.
3. Análisis espectral preliminar: Distribución de los autovalores λ_i de la matriz de covarianza Σ .

4.2. B) Limpieza y Modelado de Ruido

Asuma un modelo de observación $x_{obs} = x_{true} + \epsilon$.

1. Caracterice el ruido ϵ bajo supuestos de normalidad.
2. Detecte outliers utilizando simultáneamente el criterio de Z-score (L_2) y la **Distancia de Mahalanobis** (D_M).
3. Justifique matemáticamente por qué $D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})}$ es superior a la distancia Euclídea para detectar anomalías en este dataset.

4.3. C) Tratamiento de Valores Faltantes

Identifique el mecanismo de pérdida (MCAR, MAR o MNAR) basándose en la correlación de la ausencia.

1. **Demostración Matemática:** Demuestre formalmente que si se imputa por la media, la nueva varianza se colapsa según:

$$\sigma_{new}^2 = \frac{n}{n+m} \sigma_{obs}^2$$

donde n es el número de registros observados y m el de imputados.

2. Compare el impacto espectral en Σ de la imputación por media frente a una imputación multivariada iterativa (ej. MICE).

4.4. D) Integración y Dependencia Lineal

Si su dataset combina múltiples fuentes o presenta redundancia:

1. Realice un análisis de redundancia lineal. Identifique si existe $\mathbf{x}_j = \sum_{k \neq j} \alpha_k \mathbf{x}_k + \beta$.
2. Discuta el impacto de la multicolinealidad en el determinante $\det(\mathbf{X}^T \mathbf{X})$.

4.5. E) Transformaciones de Espacio

1. **Demostración de Invarianza:** Demuestre que el centrado de datos ($Z = X - \mathbf{1}\mu^T$) no altera la estructura de dispersión total, es decir, $\text{tr}(\Sigma)$ se mantiene constante bajo traslación.
2. **Propagación de Covarianza:** Demuestre que si $\mathbf{y} = \mathbf{W}^T \mathbf{x}$, entonces $\Sigma_Y = \mathbf{W}^T \Sigma_X \mathbf{W}$.
3. Aplique *Mean Centering* y comparta el impacto de la **Estandarización Z-score** frente al escalamiento **Min-Max** en el número de condición de la matriz final.

4.6. F) Análisis Crítico de Estabilidad

Redacte una discusión técnica sobre cómo su preprocesamiento ha condicionado el espacio para:

- Acelerar la convergencia de un futuro descenso de gradiente (redondeo de las curvas de nivel del Hessiano).
- Evitar el *Data Leakage*: Asegure que los parámetros μ, σ se calcularon estrictamente en el set de entrenamiento.

5. Rúbrica de Evaluación

Criterio	Indicador	Peso
Rigor Matemático	Uso correcto de notación matricial y formalismo algebraico.	25 %
Corrección Algebraica	Precisión en las demostraciones y cálculos espectrales.	25 %
Análisis Crítico	Capacidad de interpretar κ , $\det(\Sigma)$ y colapso de varianza.	20 %
Implementación	Código en Python (NumPy/Pandas) eficiente y libre de fugas.	15 %
Defensa Oral	Sustentación técnica de las decisiones tomadas (22-25 min).	15 %