

Mineria de Datos (CC442)

Practica Dirigida: Fundamentos Matematicos y Topologicos

Prof. Marcos Alania

Este conjunto de problemas esta diseñado para estudiantes de Ciencias de la Computación. Se requiere rigor analítico, demostraciones formales y un profundo entendimiento de la geometría multidimensional. Todas las respuestas deben ser desarrolladas a mano, detallando cada paso lógico y algebraico.

Problemas Analíticos

- 1. Propiedades de la Matriz de Covarianza (Algebra Lineal):** Sea $X \in \mathbb{R}^{n \times d}$ una matriz de datos centrada (donde la media de cada columna es cero). Demuestre rigurosamente que la matriz de covarianza $\Sigma = \frac{1}{n}X^T X$ es siempre semidefinida positiva. Explique que implicancia geometrica tiene esta propiedad cuando buscamos los vectores propios en un Analisis de Componentes Principales (PCA).
- 2. Convergencia de la Topologia de Minkowski (Analisis Real):** Dada la distancia generalizada de Minkowski L_p entre dos vectores $x, y \in \mathbb{R}^d$:

$$d_p(x, y) = \left(\sum_{k=1}^d |x_k - y_k|^p \right)^{1/p}$$

Demuestre analiticamente, usando limites, que cuando $p \rightarrow \infty$, la metrica converge a la Distancia de Chebyshev (L_∞), definida como $\max_k |x_k - y_k|$.

- 3. Equivalencia Projectiva (Trigonometria Multidimensional):** Considere dos vectores $x, y \in \mathbb{R}^d$ no nulos. Si ambos vectores son proyectados sobre la hiperesfera unitaria (es decir, se normalizan tal que $\|x\|_2 = 1$ y $\|y\|_2 = 1$), demuestre matematicamente que la distancia Euclidiana al cuadrado entre ellos es inversamente proporcional a su Similitud de Coseno. Derive la ecuacion exacta que los relaciona.
- 4. La Maldicion de la Dimensionalidad (Teorema de la Concha):** Considere un hipercubo C de dimension d centrado en el origen con lados de longitud 1. Sea C' un hipercubo interior con lados de longitud $1 - 2\varepsilon$ (donde $0 < \varepsilon < 0.5$). Demuestre matematicamente que a medida que $d \rightarrow \infty$, el volumen de la "cascara" exterior (la diferencia entre C y C') se aproxima al 100% del volumen total, implicando que en espacios de alta dimension, casi todos los datos viven en la frontera del espacio.

5. **Optimizacion del Centro de Gravedad (Calculo Vectorial):** Dada una coleccion de vectores $X = \{x_1, x_2, \dots, x_n\}$ donde $x_i \in \mathbb{R}^d$. Utilizando derivadas vectoriales y gradientes, demuestre rigurosamente que el vector que minimiza la suma de errores cuadraticos $f(c) = \sum_{i=1}^n \|x_i - c\|_2^2$ es exactamente el vector media $\mu = \frac{1}{n} \sum_{i=1}^n x_i$.
6. **Robustez del Estimador L_1 (Optimizacion Convexa):** A diferencia del problema anterior, asuma que la funcion de perdida a minimizar esta dada por la norma L_1 : $g(c) = \sum_{i=1}^n \|x_i - c\|_1$. Demuestre analiticamente por que la solucion c^* que minimiza $g(c)$ corresponde a la mediana geometrica de los datos y explique matematicamente por que esto hace que el estimador sea inmune (robusto) a outliers extremos, a diferencia del vector media.
7. **Invarianza bajo Transformaciones Ortogonales:** Sea $Y = XQ$, donde X es una matriz de datos centrada de $n \times d$ y Q es una matriz ortogonal de $d \times d$ ($Q^T Q = I$). Demuestre como se relaciona la matriz de covarianza de Y (Σ_Y) con la matriz de covarianza de X (Σ_X). Ademas, demuestre que la distancia Euclidiana entre cualquier par de instancias i, j se preserva despues de aplicar la transformacion Q .
8. **Generalizacion de la Distancia Euclidiana (Metrica de Mahalanobis):** La distancia de Mahalanobis incorpora la estructura de covarianza de los datos: $d_M(x, \mu) = \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)}$. Demuestre paso a paso que si las dimensiones de X son estadisticamente independientes y todas poseen varianza unitaria (ruido blanco), la distancia de Mahalanobis colapsa algebraicamente y se vuelve identica a la distancia Euclidiana.
9. **Regularizacion y el Riesgo Empirico (Overfitting):** Suponga que minimizamos un Riesgo Empirico dado por una regresion lineal $R_{emp}(w) = \|y - Xw\|_2^2$. Demuestre matematicamente como la adiccion de un termino de penalizacion de norma L_2 ($+\lambda \|w\|_2^2$) altera la solucion analitica de minimos cuadrados. Explique usando los valores singulares de X por que esta adiccion estabiliza el modelo frente a la colinealidad y previene el sobreajuste.
10. **Desigualdad Triangular en el Espacio de Hipotesis (Desigualdad de Minkowski):** Para que una medida geometrica sea considerada formalmente una "metrica" en Data Mining, debe satisfacer la desigualdad triangular. Utilizando la Desigualdad de Holder, demuestre la desigualdad de Minkowski: $\|x + y\|_p \leq \|x\|_p + \|y\|_p$ para $p \geq 1$. Analice criticamente: ¿por que falla esta demostracion para distancias fraccionales donde $0 < p < 1$?