

10) Obtener la desigualdad de Minkowski utilizando Holder. Analice críticamente si por qué falla la demostración para $0 < p < 1$.

Sol

Recordar la desigualdad de Holder

Sean $x, y \in \mathbb{R}^n$ y $p, q \in \mathbb{R}$ / $\frac{1}{p} + \frac{1}{q} = 1, p, q > 1$

Entonces $\sum x_i y_i \leq (\sum x_i^p)^{1/p} (\sum y_i^q)^{1/q}$

P.D $\|x+y\|_p \leq \|x\|_p + \|y\|_p \quad \forall p > 1$

En efecto:

$$\Rightarrow |x_i + y_i| \leq |x_i| + |y_i| \quad \forall i$$

$$\Rightarrow |x_i + y_i| |x_i + y_i|^{p-1} \leq (|x_i| + |y_i|) |x_i + y_i|^{p-1} \quad \forall i$$

$$\Rightarrow |x_i + y_i|^p \leq |x_i| |x_i + y_i|^{p-1} + |y_i| |x_i + y_i|^{p-1} \quad \forall i$$

$$\Rightarrow \sum |x_i + y_i|^p \leq \sum |x_i| |x_i + y_i|^{p-1} + \sum |y_i| |x_i + y_i|^{p-1}$$

Usando Holder en los 2 términos de la derecha de la desigualdad

$$\Rightarrow \sum |x_i + y_i|^p \leq (\sum |x_i|^p)^{1/p} (\sum |x_i + y_i|^{(p-1)q})^{1/q} + (\sum |y_i|^p)^{1/p} (\sum |x_i + y_i|^{(p-1)q})^{1/q}$$

Pero $\frac{1}{p} + \frac{1}{q} = 1 \Rightarrow \frac{1}{q} = 1 - \frac{1}{p} = \frac{p-1}{p} \Rightarrow \frac{p}{p-1} = q$

$$\Rightarrow p = q(p-1)$$

$$\Rightarrow \sum |x_i + y_i|^p \leq (\sum |x_i|^p)^{1/p} (\sum |x_i + y_i|^p)^{1/q} + (\sum |y_i|^p)^{1/p} (\sum |x_i + y_i|^p)^{1/q}$$

$$\Rightarrow \sum |x_i + y_i|^p \leq (\sum |x_i + y_i|^p)^{1/q} ((\sum |x_i|^p)^{1/p} + (\sum |y_i|^p)^{1/p})$$

$$\Rightarrow \frac{\sum |x_i + y_i|^p}{(\sum |x_i + y_i|^p)^{1/q}} \leq (\sum |x_i|^p)^{1/p} + (\sum |y_i|^p)^{1/p}$$

$$\Rightarrow (\sum |x_i + y_i|^p)^{1-\frac{1}{q}} \leq (\sum |x_i|^p)^{1/p} + (\sum |y_i|^p)^{1/p}$$

$$p \rightarrow \infty \quad 1 - \frac{1}{q} = \frac{1}{p}$$

$$\Rightarrow (\sum |x_i + y_i|^p)^{1/p} \leq (\sum |x_i|^p)^{1/p} + (\sum |y_i|^p)^{1/p}$$

$$\Rightarrow \|x + y\|_p \leq \|x\|_p + \|y\|_p, \quad \forall p > 1$$

* Veamos para el caso $p=1$

$$\Rightarrow |x_i + y_i| \leq |x_i| + |y_i| \quad \forall i$$

$$\Rightarrow \sum |x_i + y_i| \leq \sum |x_i| + \sum |y_i| \quad \forall i$$

$$\Rightarrow \|x + y\|_1 \leq \|x\|_1 + \|y\|_1$$

* Veamos ahora para $0 < p < 1$

$$\Rightarrow p-1 < 0 \text{ y como } q = \frac{p}{p-1} < 0$$

$$\Rightarrow q < 0, \quad p < 1 \quad (\text{No cumple las hipótesis del teorema de Hölder})$$

$$\text{G.O.} \quad \|x + y\|_p \leq \|x\|_p + \|y\|_p, \quad \forall p \geq 1$$

2) Convergencia de la Topología de Minkowski
 Sea la distancia generalizada de Minkowski
 L^p entre dos vectores en $\mathbb{R}^d$

$$d_p(x, y) = \left(\sum_{i=1}^d |x_i - y_i|^p \right)^{1/p} \quad \forall x, y \in \mathbb{R}^d$$

Demstrar $\lim_{p \rightarrow \infty} d_p(x, y) = \max_k |x_k - y_k|$

Sol

En efecto,

$$\exists j / M = |x_j - y_j| \text{ el maximo en } d$$

Caso 1: Si $M = 0$

$$\Rightarrow \exists j / M = 0 = |x_j - y_j|$$

$$\Rightarrow 0 \leq |x_i - y_i| \leq M = 0 \quad \forall i$$

$$\Rightarrow |x_i - y_i| = 0 \quad \forall i \Rightarrow \max_k |x_k - y_k| = 0$$

$$\Rightarrow d_p(x, y) = 0 = \max_k |x_k - y_k|$$

Así $\lim_{p \rightarrow \infty} d_p(x, y) = \lim_{p \rightarrow \infty} 0 = 0 = \max_k |x_k - y_k|$

$$\circ \circ \lim_{p \rightarrow \infty} d_p(x, y) = \max_k |x_k - y_k|$$

Caso 2: Si $M > 0$

Así: $|x_i - y_i| \leq M \quad \forall i \Rightarrow |x_i - y_i|^p \leq M^p \quad \forall i$

$$\Rightarrow \sum |x_i - y_i|^p \leq \sum M^p = M^p \cdot d$$

$$\Rightarrow (\sum |x_i - y_i|^p)^{1/p} \leq d^{1/p} M \dots (\alpha)$$

Además:

$$\sum |x_i - y_i|^p = \underbrace{|x_1 - y_1|^p + \dots + |x_j - y_j|^p}_{\geq 0} + \dots + \underbrace{|x_d - y_d|^p}_{\geq 0}$$

↓ Pos. j

$$\Rightarrow \sum |x_i - y_i|^p \geq M^p \Rightarrow (\sum |x_i - y_i|^p)^{1/p} \geq M \dots (\beta)$$

De (α) y (β) tenemos:

$$M \leq (\sum |x_i - y_i|^p)^{1/p} \leq d^{1/p} M \dots (\gamma)$$

Además:

$$d^{1/p} = e^{\frac{\ln d}{p}} = e^{\frac{\ln d}{p}}$$

$$\text{Así: } \frac{\ln d}{p} \xrightarrow{p \rightarrow \infty} 0$$

$$\Rightarrow \lim_{p \rightarrow \infty} d^{1/p} = \lim_{p \rightarrow \infty} e^{\frac{\ln d}{p}} = e^{\lim_{p \rightarrow \infty} \frac{\ln d}{p}} = e^0 = 1$$

$$\Rightarrow d^{1/p} \xrightarrow{p \rightarrow \infty} 1$$

Usando lo obtenido en (γ) , cuando $p \rightarrow \infty$:

$$M \leq (\sum |x_i - y_i|^p)^{1/p} \leq d^{1/p} M$$

↓

M

↓

M

$$\Leftrightarrow \lim_{p \rightarrow \infty} (\sum |x_i - y_i|^p)^{1/p} = M = \max_k |x_k - y_k|$$

$$\Leftrightarrow \lim_{p \rightarrow \infty} d_p(x, y) = \max_k |x_k - y_k|$$

1) Sea $X \in \mathbb{R}^{n \times d}$ una matriz centrada. Demostrar que la matriz de covarianza $\Sigma = \frac{1}{n} X^T X$ es positiva. Explicar la implicación geométrica de esta propiedad cuando buscamos los vectores propios en un análisis de PCA.

Sol

PD $v^T \Sigma v \geq 0 \quad \forall v \in \mathbb{R}^d$

En efecto:

Sea $v \in \mathbb{R}^d$, y $\Sigma = \frac{1}{n} X^T X$

$$\Rightarrow v^T \Sigma v = v^T \left(\frac{1}{n} X^T X \right) v = \frac{1}{n} v^T X^T X v$$

$$= \frac{1}{n} (Xv)^T (Xv) = \frac{1}{n} \|Xv\|_2^2 \geq 0$$

$\therefore v^T \Sigma v \geq 0 \quad \forall v \in \mathbb{R}^d$

Así, Σ es positivo.

Veamos la interpretación geométrica.

Como $X = \begin{pmatrix} X_1^T \\ X_2^T \\ \vdots \\ X_n^T \end{pmatrix} \in \mathbb{R}^{n \times d}$, $X_i \in \mathbb{R}^d$, $v \in \mathbb{R}^d$

$$\Rightarrow Xv = \begin{pmatrix} X_1^T v \\ X_2^T v \\ \vdots \\ X_n^T v \end{pmatrix} \in \mathbb{R}^n \Rightarrow \|Xv\| = \sqrt{\sum_{i=1}^n (X_i^T v)^2}$$

Así definimos $Z_i := X_i^T v$

$$\Rightarrow Xv = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix} \in \mathbb{R}^n \Rightarrow \bar{z} := \frac{1}{n} \sum_{i=1}^n z_i = \frac{1}{n} \sum_{i=1}^n X_i^t v$$

$$\Rightarrow \text{Var}(Xv) := \frac{1}{n} \sum_{i=1}^n (X_i^t v - \bar{z})^2$$

Para nuestro problema X es centrado

$$\Rightarrow \frac{1}{n} \sum_{i=1}^n X_i = 0.$$

$$\Rightarrow \bar{z} = \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^t v = \frac{1}{n} \sum_{i=1}^n X_i^t v = 0$$

Entonces se cumple:

$$\text{Var}(Xv) = \frac{1}{n} \sum_{i=1}^n (X_i^t v)^2 = \frac{1}{n} \|Xv\|_2^2 = \frac{1}{n} (Xv)^t (Xv)$$

$$= \frac{1}{n} v^t X^t X v = v^t \left(\frac{1}{n} X^t X \right) v = v^t \Sigma v$$

$$\Rightarrow \text{Var}(Xv) = v^t \Sigma v \quad / \quad v^t v = 1$$

Construimos el lagrangiano

$$L(v, \lambda) = v^t \Sigma v - \lambda (v^t v - 1) \Rightarrow \nabla_v L = 0$$

$$\Rightarrow 2\Sigma v - 2\lambda v = 0 \Rightarrow \Sigma v = \lambda v$$

Así v_λ autovector asociado de λ , de Σ , el cual


maximiza Varianza de Xv

3) Sean $x, y \in \mathbb{R}^d \setminus \{0\}$ t.q. $\|x\| = \|y\| = 1$.

• Se define la similitud de coseno como

$$\text{Sim}(a, b) = \frac{a^t b}{\|a\| \|b\|} \quad \forall a, b \in \mathbb{R}^d \setminus \{0\}$$

• Pero se sabe que el ángulo entre dos vectores u, v se define



$$\text{Cose} = \frac{u \cdot v}{\|u\| \|v\|}$$

$u, v \in V \setminus \{0\}$
↑ esp. vect.

• Así trasladando la definición de ángulo entre 2 vectores a sim. tenemos

$$\text{Sim}(a, b) = \frac{a^t b}{\|a\| \|b\|} = \text{Cose} \theta$$

• Para nuestro problema $x, y \in \mathbb{R}^d / \|x\| = \|y\| = 1$

$$\Rightarrow d^2(x, y) = \|x - y\|^2 = (x - y)^t (x - y)$$

$$= (x^t - y^t)(x - y) = x^t(x - y) - y^t(x - y)$$

$$= x^t x - x^t y - y^t x + y^t y$$

$$= \|x\|^2 + \|y\|^2 - 2x^t y$$

$$\Rightarrow d^2(x, y) = 2 - 2x^t y / \text{Pero } \text{Cose} \theta = \frac{x^t y}{\|x\| \|y\|} = x^t y$$

$$\Rightarrow d^2(x, y) = 2 - 2\text{Cose}$$

$$\text{so } \text{Cose} = 1 - \frac{1}{2} d^2(x, y), \quad \forall x, y \in \mathbb{R}^d \setminus \{0\} \text{ t.q. } \|x\| = \|y\| = 1$$

5) Dada una colección de vectores $X = \{x_1, \dots, x_n\}$ t.q. $x_i \in \mathbb{R}^d$ $\forall i$. Demostrar que el vector que minimiza la suma de errores cuadráticos $f(c) = \sum_{i=1}^n \|x_i - c\|_2^2$ es el vector $\mu = \frac{1}{n} \sum_{i=1}^n x_i$.

Sol
Defino la función $f: \mathbb{R}^d \rightarrow \mathbb{R}$
 $c \mapsto f(c) = \sum_{i=1}^n \|x_i - c\|_2^2$

Usamos primero

$$\Rightarrow \|x_i - c\|_2^2 = (x_i - c)^t (x_i - c) = (x_i^t - c^t)(x_i - c)$$

$$= x_i^t (x_i - c) - c^t (x_i - c) = x_i^t x_i - x_i^t c - c^t x_i + c^t c$$

$$\Rightarrow \|x_i - c\|_2^2 = \sum_{i=1}^n x_i^t x_i - 2c^t \sum_{i=1}^n x_i + n c^t c = f(c) \dots (*)$$

Además, las variables son $c_1, c_2, \dots, c_n \in \mathbb{R}$ t.q.

$$c = \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix} \in \mathbb{R}^n \text{ y sea } a = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix} \in \mathbb{R}^n$$

$$\Rightarrow c^t c = c_1^2 + c_2^2 + \dots + c_n^2 \Rightarrow \nabla(n c^t c) = n \nabla(c^t c)$$

$$= n \begin{pmatrix} 2c_1 \\ 2c_2 \\ \vdots \\ 2c_n \end{pmatrix} = 2n \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix} = 2nc$$

$$\Rightarrow \nabla(n c^t c) = 2nc$$

$$\Rightarrow c^t a = \sum_{i=1}^n c_i a_i \Rightarrow \nabla(c^t a) = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix} \in \mathbb{R}^n \Rightarrow \nabla(c^t a) = a$$

$$\text{Así: } \nabla(-2c^t \sum_{i=1}^n x_i) = -2 \sum_{i=1}^n x_i$$

Como queremos averiguar el máximo de $f(c)$ tenemos la gradiente de la función $f(c)$, en c y lo igualamos a cero.

$$\Rightarrow \nabla f(c) = \nabla \left(\sum_{i=1}^n x_i^T x_i - 2c^T \sum_{i=1}^n x_i + nc \right)$$

$$= \nabla \left(\sum_{i=1}^n x_i^T x_i \right) + \nabla \left(-2c^T \sum_{i=1}^n x_i \right) + \nabla (nc)$$

$$= -2 \sum_{i=1}^n x_i + 2nc$$

$$\Rightarrow \nabla f(c) = -2 \sum_{i=1}^n x_i + 2nc = \underline{0}$$

$$\Rightarrow c = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\Rightarrow \mu = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{Este vector puede maximizar o minimizar } f(c))$$

Para ver si μ es máximo o mínimo usamos el Hesseano.

$$\Rightarrow f(c) = (f_1(c), f_2(c), \dots, f_d(c))^T \in \mathbb{R}^d$$

$$\Rightarrow \nabla^2 f(c) = \begin{pmatrix} \frac{\partial^2 f_1}{\partial c_1^2} & \frac{\partial^2 f_1}{\partial c_1 \partial c_2} & \dots & \frac{\partial^2 f_1}{\partial c_1 \partial c_n} \\ \frac{\partial^2 f_2}{\partial c_2 \partial c_1} & \frac{\partial^2 f_2}{\partial c_2^2} & \dots & \frac{\partial^2 f_2}{\partial c_2 \partial c_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f_n}{\partial c_n \partial c_1} & \frac{\partial^2 f_n}{\partial c_n \partial c_2} & \dots & \frac{\partial^2 f_n}{\partial c_n^2} \end{pmatrix} = \begin{pmatrix} \frac{\partial \nabla f_1(c)}{\partial c_1} & \frac{\partial \nabla f_1(c)}{\partial c_2} & \dots & \frac{\partial \nabla f_1(c)}{\partial c_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \nabla f_n(c)}{\partial c_1} & \frac{\partial \nabla f_n(c)}{\partial c_2} & \dots & \frac{\partial \nabla f_n(c)}{\partial c_n} \end{pmatrix}$$

$$\Rightarrow \nabla^2 f(c) = 2n \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_d \end{pmatrix} = 2 \sum_{i=1}^n x_i \quad \begin{matrix} \text{no depende} \\ \text{de } c_i \forall i \end{matrix}$$

$$\Rightarrow \nabla^2 f(c) = \begin{pmatrix} 2n & 0 & \dots & 0 \\ 0 & 2n & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 2n \end{pmatrix} = 2n I_d$$

Evaluando en μ y viendo si es positiva o negativa.
Así, sea $v \in \mathbb{R}^d \setminus \{0\}$?

$$\Rightarrow v^t \nabla^2 f(\mu) v = v^t 2n I_d v = 2n \cdot v^t v = 2n \|v\|_2^2 \geq 0.$$

$$\Rightarrow \nabla^2 f(\mu) \geq 0 \text{ (Es positiva)}$$

$\Rightarrow \mu$ es mínimo local.

o El vector $\mu = \frac{1}{n} \sum_{i=1}^n x_i$

minimiza a la función $f(x) = \sum_{i=1}^n \|x_i - x\|_2^2$

7) Sea $Y = XQ$, donde X es matriz de datos centrados $n \times d$ y Q una matriz ortogonal de $d \times d$. Demostrar la relevancia de Σ_X y Σ_Y . Además demostrar que la distancia euclidiana entre cualquier par de puntos i, j se preserva después de aplicar la transformación Q .

Sol

- Sea X una matriz centrada entonces se cumple

$$\Sigma_X = \frac{1}{n} X^T X$$

- Cuando una matriz es centrada se debe cumplir:

$$\left\{ \begin{array}{l} \text{Si } X \in \mathbb{R}^{n \times d}, X = (X_{ij}) \Rightarrow \frac{1}{n} \sum_{i=1}^n X_{ij} = 0 \quad \forall j \in [0, d] \\ \text{ó de otra manera} \\ \text{Si } X \in \mathbb{R}^{n \times d}, \mathbf{1}_n = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \in \mathbb{R}^n, \mathbf{0} \in \mathbb{R}^d \Rightarrow \frac{1}{n} \mathbf{1}_n^T X = \mathbf{0} \end{array} \right.$$

- A#1: Yes centrada

Por hip. tenemos que X centrada $\Rightarrow \frac{1}{n} \mathbf{1}_n^T X = \mathbf{0}$

$$\Rightarrow \frac{1}{n} \mathbf{1}_n^T Y = \frac{1}{n} \mathbf{1}_n^T (XQ) = \left(\frac{1}{n} \mathbf{1}_n^T X \right) Q = \mathbf{0} Q = \mathbf{0}$$

$\Rightarrow Y$ es matriz centrada

- A#2: Σ_X, Σ_Y son semejantes ($\Sigma_Y = Q^T \Sigma_X Q$)

Como Y es centrada, se usa la def. matriz de covarianza

$$\begin{aligned}\Sigma_Y &= \frac{1}{n} Y^t Y = \frac{1}{n} (XQ)^t (XQ) = \frac{1}{n} Q^t X^t X Q \\ &= Q^t \left(\frac{1}{n} X^t X \right) Q = Q^t \underbrace{\Sigma_X}_{\Sigma_X} Q\end{aligned}$$

$$\Rightarrow \Sigma_Y = Q^t \Sigma_X Q$$

Pero Q es una matriz ortogonal, entonces

$$Q^t Q = Q Q^t = I_d \Rightarrow Q^t = Q^{-1}$$

$$\Rightarrow \Sigma_Y = Q^{-1} \Sigma_X Q$$

Así Σ_Y , Σ_X son semejantes ($\Sigma_Y = Q^{-1} \Sigma_X Q$)

A.3: Sean x_i, x_j dos observaciones de $X \in \mathbb{R}^{n \times d}$, $x_i, x_j \in \mathbb{R}^d$
Entonces $\|x_i - x_j\|_2 = \|Q(x_i - x_j)\|_2$

En efecto:

$$\begin{aligned}\|Q(x_i - x_j)\|_2^2 &= (Q(x_i - x_j))^t (Q(x_i - x_j)) = (x_i - x_j)^t \underbrace{Q^t Q}_{I_d} (x_i - x_j) \\ &= (x_i - x_j)^t (x_i - x_j) = \|x_i - x_j\|_2^2\end{aligned}$$

$$\Rightarrow \|x_i - x_j\|_2 = \|Q(x_i - x_j)\|_2 \quad \blacktriangle$$

8) Se define la distancia Mahalanobis.

Sea $X \in \mathbb{R}^{n \times d}$ y su matriz de covarianza Σ_X con $\mu_X \in \mathbb{R}^d$ (Vector de media). Sea $X_i \in \mathbb{R}^d$ una observación de X , se define la distancia Mahalanobis de X_i hacia la media como

$$d_M(X_i, \mu) = \sqrt{(X_i - \mu_X)^T \Sigma_X^{-1} (X_i - \mu_X)}$$

Demostar que si las variables son independientes con Varianza 1, entonces

$$d_M(X_i, \mu) = \|X_i - \mu\|_2$$

Sol

Sea $X \in \mathbb{R}^{n \times d}$, así definimos $X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix}$

y $X_i \in \mathbb{R}^d$

Se define la matriz de covarianza de X como:

$$\Sigma_X = (\text{Cov}(X_i, X_j)) \quad , \quad i, j \in [1, d]$$

Por definición tenemos

$$(*) \dots \text{Cov}(X_i, X_j) = E[X_i X_j] - E[X_i] E[X_j] \quad \forall i \neq j$$

Por hipótesis X_i, X_j son independientes $i \neq j$

$$\Rightarrow E[X_i X_j] = E[X_i] E[X_j]$$

Usando lo ultimo au(*) tenemos

$$\text{Cov}(x_i, x_j) = 0 \quad \forall i \neq j$$

Ademas por hipotesas se tiene.

$$V(x_i) = \text{Cov}(x_i, x_i) = 1$$

Asi tendremos Σ_x :

$$\Sigma_x = (\text{Cov}(x_i, x_j)) = \begin{pmatrix} \text{Cov}(x_1, x_1) & \text{Cov}(x_1, x_2) & \dots & \text{Cov}(x_1, x_d) \\ \text{Cov}(x_2, x_1) & \text{Cov}(x_2, x_2) & \dots & \text{Cov}(x_2, x_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(x_d, x_1) & \text{Cov}(x_d, x_2) & \dots & \text{Cov}(x_d, x_d) \end{pmatrix}$$

$$\Rightarrow \Sigma_x = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \end{pmatrix} \Rightarrow \Sigma_x = I_d \Rightarrow \Sigma_x^{-1} = I_d$$

Asi tendremos

$$\begin{aligned} d_M(x_i, \mu) &= \sqrt{(x_i - \mu)^t \Sigma_x^{-1} (x_i - \mu)} = \sqrt{(x_i - \mu)^t (x_i - \mu)} \\ &= \sqrt{\|x_i - \mu\|_2^2} = \|x_i - \mu\|_2 \end{aligned}$$

$$\circ \circ \quad d_M(x_i, \mu) = \|x_i - \mu\|_2$$

9) Sea la Regresión lineal ordinaria

$$R_{\text{ord}}(w) = \|y - Xw\|_2^2 \quad \dots (4)$$

donde $X \in \mathbb{R}^{n \times d}$, $w \in \mathbb{R}^d$, $y \in \mathbb{R}^n$

El cual tiene una solución analítica w_1 que minimiza (*).

Sea ahora

$$(**) \dots R_\lambda(w) = \|y - Xw\|_2^2 + \lambda \|w\|_2^2, \lambda > 0$$

El cual tiene una solución analítica w_2 que minimiza (**).

Se puede ver la relación entre w_1 , w_2 , usando los valores singulares de X . Por que la regularización estabiliza el problema frente a colinealidad y sobreajuste.

Sol

• Sea el problema encaja $f(w) = \|y - Xw\|_2^2$

$$\Rightarrow f(w) = (y - Xw)^T (y - Xw) = (y^T - (Xw)^T)(y - Xw)$$

$$= (y^T - w^T X^T)(y - Xw)$$

$$= y^T (y - Xw) - w^T X^T (y - Xw)$$

$$= y^T y - y^T Xw - w^T X^T y + w^T X^T Xw \dots (4)$$

Pero: $y^t x w \in \mathbb{R} \Rightarrow (y^t x w)^t = (y^t x w)$

Así $(y^t x w)^t = w^t x^t (y^t)^t = w^t x^t y = (y^t x w)$

Reemplazando en (**):

$$f(w) = y^t y - 2w^t x^t y + w^t x^t x w$$

Buscaremos el gradiente de la función f para lo cual, usamos unos resultados previos.

• Sea $x \in \mathbb{R}^{n \times d}$, $w \in \mathbb{R}^{d \times 1}$, $y \in \mathbb{R}^{n \times 1}$. t_y

$$w = \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \end{pmatrix} \in \mathbb{R}^{d \times 1}, A = (a_{ij}) = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1d} \\ a_{21} & a_{22} & a_{23} & \dots & a_{2d} \\ \dots & \dots & \dots & \dots & \dots \\ a_{d1} & a_{d2} & a_{d3} & \dots & a_{dd} \end{pmatrix} \in \mathbb{R}^{d \times d}$$

$$\Rightarrow Aw = \begin{pmatrix} a_{11}w_1 + a_{12}w_2 + a_{13}w_3 + \dots + a_{1d}w_d \\ a_{21}w_1 + a_{22}w_2 + a_{23}w_3 + \dots + a_{2d}w_d \\ \dots \\ a_{d1}w_1 + a_{d2}w_2 + a_{d3}w_3 + \dots + a_{dd}w_d \end{pmatrix} \in \mathbb{R}^{d \times 1}$$

$$Aw = \begin{pmatrix} \sum_{j=1}^d a_{1j}w_j \\ \sum_{j=1}^d a_{2j}w_j \\ \dots \\ \sum_{j=1}^d a_{dj}w_j \end{pmatrix} \in \mathbb{R}^{d \times 1}$$

$$\Rightarrow w^t Aw = (w_1 \ w_2 \ w_3 \ \dots \ w_d)$$

$$\begin{pmatrix} \sum_{j=1}^d a_{1j}w_j \\ \sum_{j=1}^d a_{2j}w_j \\ \sum_{j=1}^d a_{3j}w_j \\ \dots \\ \sum_{j=1}^d a_{dj}w_j \end{pmatrix}$$

$$\Rightarrow \nabla(w^T A w) = \begin{pmatrix} \sum_{j=1}^d a_{1j} w_j + a_{11} w_1 + a_{21} w_2 + a_{31} w_3 + \dots + a_{d1} w_d \\ a_{12} w_1 + \sum_{j=1}^d a_{2j} w_j + a_{22} w_2 + a_{32} w_3 + \dots + a_{d2} w_d \\ a_{13} w_1 + a_{23} w_2 + \sum_{j=1}^d a_{3j} w_j + a_{33} w_3 + \dots + a_{d3} w_d \\ \vdots \\ a_{1d} w_1 + a_{2d} w_2 + a_{3d} w_3 + a_{4d} w_4 + \dots + \sum_{j=1}^d a_{dj} w_j + a_{dd} w_d \end{pmatrix}$$

$$n \begin{pmatrix} a_{11}w_1 + a_{12}w_2 + a_{13}w_3 + \dots + a_{1d}w_d \\ a_{21}w_1 + a_{22}w_2 + a_{23}w_3 + \dots + a_{2d}w_d \\ \vdots \\ a_{d1}w_1 + a_{d2}w_2 + a_{d3}w_3 + \dots + a_{dd}w_d \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^d a_{1j}w_j \\ \sum_{j=1}^d a_{2j}w_j \\ \vdots \\ \sum_{j=1}^d a_{dj}w_j \end{pmatrix}$$

$$= A^T \omega + A \omega = (A^T + A) \omega$$

Así se prueba. y c

$$\nabla(\omega^T A \omega) = (A^T + A) \omega$$

• Sei $w \in \mathbb{R}^{d \times 1}$, $z \in \mathbb{R}^{d \times 1}$ / $z = (a_1, \dots, a_d)^t$

$$w^T a = (w_1, w_2, \dots, w_d) \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_d \end{pmatrix} = a_1 w_1 + a_2 w_2 + \dots + a_d w_d$$

$\Rightarrow \nabla(w^t a) = (a_1, a_2, \dots, a_d)^t = a$, Assim se prova

$$\nabla(\omega^f z) = z$$

- Tomando la gradiente de $f(w)$ y usando los 2 hechos anteriores.

$$\begin{aligned}
 \nabla f(w) &= \nabla (y^t y - 2w^t x^t y + w^t x^t x w) \\
 &= \cancel{\nabla (y^t y)} - 2 \nabla (w^t x^t y) + \nabla (w^t x^t x w) \\
 &= -2 x^t y + (x^t x + (x^t x)^t) w \\
 &= -2 x^t y + 2 x^t x w.
 \end{aligned}$$

Así: $\nabla f(w) = -2 x^t y + 2 x^t x w.$

Así: $\nabla f(w) = 0 \Rightarrow w_1 = (x^t x)^{-1} x^t y$

- Veamos el problema ampliado.

$$g(w) = \|y - Xw\|_2^2 + \lambda \|w\|_2^2$$

→ Primero veamos

$$\lambda \|w\|_2^2 = \lambda (w_1, w_2, \dots, w_d) \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \end{pmatrix}$$

$$= \lambda (w_1^2 + w_2^2 + \dots + w_d^2)$$

$$\Rightarrow \nabla (\lambda \|w\|_2^2) = \lambda \begin{pmatrix} 2w_1 \\ 2w_2 \\ \vdots \\ 2w_d \end{pmatrix} = 2\lambda w$$

$$\therefore \nabla (\lambda \|w\|_2^2) = 2\lambda w$$

→ Tomando la gradiente de $g(w)$ y usando el último hecho.

$$\begin{aligned}\Rightarrow \nabla g(w) &= \nabla (\|y - Xw\|_2^2 + \lambda \|w\|_2^2) \\ &= \nabla (\|y - Xw\|_2^2) + \nabla (\lambda \|w\|_2^2) \\ &= -2X^t y + 2X^t X w + 2\lambda w.\end{aligned}$$

Así $\nabla g(w) = 0$.

$$\Rightarrow -2X^t y + 2X^t X w + 2\lambda w = 0.$$

$$\Rightarrow (X^t X + \lambda I_d) w = X^t y.$$

$$\Rightarrow w_2 := (X^t X + \lambda I_d)^{-1} X^t y.$$

Resumiendo

Para el problema no regulado, tenemos

$$w_1 = (X^t X)^{-1} X^t y$$

Para el problema regularizado tenemos

$$w_2 = (X^t X + \lambda I_d)^{-1} X^t y.$$

4) Sea un hipercubo C de dimensiones d , centrado en el origen con lado 1. Sea C' un hipercubo interior con lados de longitud $1-2\varepsilon$ ($0 < \varepsilon < \frac{1}{2}$). Demostrar que a medida que $d \rightarrow \infty$ el volumen de la cascara exterior (diferencia de C, C') se aproxima al 100% del Volumen total.

Sol

$$\text{Sea } C = [-\frac{1}{2}, \frac{1}{2}]^d \Rightarrow \text{Vol } C = 1^d \Rightarrow \text{Vol } C = 1$$

$$\text{Además } C' = [-\frac{1}{2} + \varepsilon, \frac{1}{2} - \varepsilon]^d \Rightarrow \text{Vol } C' = (1-2\varepsilon)^d$$

$$\text{Cascara} = C \setminus C' \text{ y } C \subseteq C'$$

$$\Rightarrow \text{Vol}(\text{Cascara}) = \text{Vol } C - \text{Vol } C'$$

$$\text{Vol}(\text{Cascara}) = 1 - (1-2\varepsilon)^d$$

Entonces

$$\frac{\text{Vol}(C \setminus C')}{\text{Vol}(C)} = \frac{1 - (1-2\varepsilon)^d}{1} \dots (*)$$

$$\text{Además } 0 < \varepsilon < \frac{1}{2}$$

$$\Rightarrow 0 < 1-2\varepsilon < 1 \text{ y haciendo } r := 1-2\varepsilon$$

$$\Rightarrow 0 < r < 1, \text{ tomando límite cuando } d \rightarrow \infty$$

$$\Rightarrow \lim_{d \rightarrow \infty} r^d = \lim_{d \rightarrow \infty} e^{\ln r^d} = e^{\lim_{d \rightarrow \infty} d \ln r}$$

Para $0 < r < 1 \Rightarrow \ln r < 0$.

$$\Rightarrow \lim_{d \rightarrow \infty} r^d = e^{\lim_{d \rightarrow \infty} d \ln r} = e^{-\infty} = 0.$$

Tomando límite $d \rightarrow \infty$ en (*)

$$\lim_{d \rightarrow \infty} \frac{\text{Vol}(C|C^d)}{\text{Vol}(C)} = \lim_{d \rightarrow \infty} [1 - (1 - 2\varepsilon)^d]$$

Usando $1 - 2\varepsilon = r$ con $0 < r < 1$.

$$\Rightarrow \lim_{d \rightarrow \infty} \frac{\text{Vol}(C|C^d)}{\text{Vol}(C)} = \lim_{d \rightarrow \infty} [1 - r^d] = 1$$

$$\Rightarrow \lim_{d \rightarrow \infty} \frac{\text{Vol}(C|C^d)}{\text{Vol}(C)} = 1$$

∴ Volumen de la cascara exterior se aproxima al 100% del Volumen total. ▲

6) Sea $g: \mathbb{R}^d \rightarrow \mathbb{R}$
 $c \mapsto g(c) = \sum_{i=1}^n \|x_i - c\|_1$

Donde:

$$x_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{id} \end{pmatrix} \in \mathbb{R}^d, \quad c = \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_d \end{pmatrix} \in \mathbb{R}^d$$

Demuestra que c^* minimiza $g(c)$, donde c^* es la media

Indique análogamente por qué c^* es un estimador robusto a outliers.

Sol

$$\|x_i - c\|_1 = \left\| \begin{pmatrix} x_{i1} - c_1 \\ x_{i2} - c_2 \\ \vdots \\ x_{id} - c_d \end{pmatrix} \right\|_1 = \sum_{j=1}^d |x_{ij} - c_j|$$

$$\Rightarrow g(c) = \sum_{i=1}^n \sum_{j=1}^d |x_{ij} - c_j| = \sum_{j=1}^d \sum_{i=1}^n |x_{ij} - c_j|$$

$$\text{Haciendo } g_j(c_j) := \sum_{i=1}^n |x_{ij} - c_j|$$

$$\Rightarrow g(c) = \sum_{j=1}^d g_j(c_j)$$

• fijando la coordenada j y escribimos

$$a_i = x_{ij}$$

debemos minimizar la función $\phi(t)$.

$$\text{ic, } \phi(t) = \sum_{i=1}^n |a_i - t|$$

$$\Rightarrow \frac{d}{dt} |a_i - t| = \begin{cases} -1, & t < a_i \\ 1, & a_i \leq t \end{cases} = \text{sgn}(t - a_i) / t \neq a_i$$

$$\Rightarrow \phi'(t) = \sum_{i=1}^n \text{sgn}(t - a_i) = N^-(t) - N^+(t)$$

Donde

$$N^-(t) = \# \{ i : a_i < t \}$$

$$N^+(t) = \# \{ i : a_i \leq t \}$$

Así, el mínimo ocurre donde la derivada cambia de negativo a positivo, el cual es la mediana

$$c^* = \begin{pmatrix} \text{med}(x_{11}, \dots, x_{n_1}) \\ \text{med}(x_{12}, \dots, x_{n_2}) \\ \vdots \\ \text{med}(x_{1d}, \dots, x_{n_d}) \end{pmatrix}$$

A