

Práctica Dirigida: Fundamentos del Preprocesamiento de Datos

Curso de Minería de Datos CC442

Prof. Marcos Alania

Parte I: El Preprocesamiento como Transformación Topológica y Métrica

1. **Preservación Métrica Estricta:** Sea $\mathcal{T} : \mathbb{R}^d \rightarrow \mathbb{R}^k$ una transformación lineal del preprocesamiento dada por $\mathcal{T}(x) = Ax$. Demuestre algebraicamente que si la matriz A satisface $A^T A = I$, entonces la distancia euclidiana se preserva exactamente entre el espacio crudo y el procesado: $d(x_i, x_j) = d(\mathcal{T}(x_i), \mathcal{T}(x_j))$.
2. **Condicionamiento Métrico y Convergencia:** Considere que el condicionamiento de un espacio métrico afecta la convergencia en Machine Learning. Si $\mathcal{T}$ transforma los datos aplicando un escalamiento dispar, $A = \text{diag}(\lambda_1, \lambda_2)$ con $\lambda_1 \gg \lambda_2$. Demuestre cómo esta distorsión métrica altera la curvatura de la función de costo cuadrática y explique por qué esto ralentiza la convergencia del gradiente descendente.
3. **Homeomorfismos y Topología:** Dado el axioma $d(x_i, x_j) \approx d(\mathcal{T}(x_i), \mathcal{T}(x_j))$, formalice esta propiedad asumiendo que $\mathcal{T}$ es una función bi-Lipschitz. Establezca y demuestre los límites teóricos del error de vecindad que un algoritmo de k -Nearest Neighbors (k-NN) podría sufrir tras aplicar $\mathcal{T}$.

Parte II: Calidad de Datos, Ruido e Inflación del Espectro

4. **Descomposición de Varianza bajo Aditividad:** Demuestre formalmente que si $X_{obs} = X_{true} + \epsilon$, donde X_{true} y el ruido ϵ son variables aleatorias estadísticamente independientes, se cumple la igualdad matricial: $\text{Var}(X_{obs}) = \text{Var}(X_{true}) + \text{Var}(\epsilon)$.
5. **Inflación Espectral:** Asumiendo que el ruido es un proceso estocástico gaussiano isotrópico $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$, demuestre rigurosamente mediante el polinomio característico que los autovalores de la matriz de covarianza observada son $\lambda_{i,obs} = \lambda_{i,true} + \sigma^2$.
6. **Invariancia de Autovectores:** Basado en la pregunta anterior, pruebe analíticamente que la base ortogonal de autovectores (componentes principales) de Σ_{obs} se mantiene idéntica a la de Σ_{true} bajo condiciones de ruido blanco isotrópico.
7. **Perturbación de PCA por Ruido Anisotrópico:** Suponga ahora que el ruido no es isotrópico, siendo $\Sigma_{ruido} = \text{diag}(\sigma_1^2, 0, \dots, 0)$ donde σ_1^2 es arbitrariamente grande. Demuestre cómo el primer componente principal derivado de X_{obs} diverge del subespacio real de los datos latentes X_{true} .
8. **Límites del Riesgo Empírico:** El ruido difumina la frontera de decisión. Para un modelo de clasificación lineal probabilístico $P(y = 1|x) = \sigma(w^T x)$, demuestre cómo el ruido gaussiano aditivo en x incrementa la cota inferior del riesgo empírico esperado (sesgo hacia 0.5).

Parte III: Detección de Outliers 1D y el Efecto de Enmascaramiento

9. **Robustez del Umbral de Shewhart:** El criterio establece considerar outlier si $|z_i| > 3$, fundamentado en $P(|Z| > 3) \approx 0,0027$ para la distribución normal. Utilice la Desigualdad de Chebyshev para hallar la cota máxima teórica de esta probabilidad para una distribución desconocida de varianza finita, y compare matemáticamente ambos escenarios.
10. **Demostración Analítica del Efecto Masking (Parte 1):** Sea un conjunto $x_1, \dots, x_N$ con media muestral 0 y varianza 1. Se añade un outlier extremo $x_{N+1} = M$. Demuestre que a medida que el valor anómalo tiende al infinito ($M \rightarrow \infty$), su Z-score z_{N+1} asintóticamente tiende a $\frac{N}{\sqrt{N}} = \sqrt{N}$, y nunca al infinito.
11. **Demostración Analítica del Efecto Masking (Parte 2):** Basado en el límite anterior $\lim_{M \rightarrow \infty} z_{N+1} = \sqrt{N}$, demuestre numéricamente por qué para conjuntos pequeños (ej. $N \leq 9$), es matemáticamente imposible que un único outlier infinito cruce el umbral de 3σ en el Z-score muestral.
12. **Soluciones Robustas:** Demuestre que el punto de ruptura asintótico (breakdown point) del estimador Mediana es 0,5 (50 %), a diferencia del estimador de media $\bar{x} = \frac{1}{N} \sum x_i$ que es del 0 % y sucumbe ante $x_{outlier} \rightarrow \infty$.

Parte IV: Detección N-D y la Geometría de Mahalanobis

13. **Invariancia Afín:** Demuestre algebraicamente que la distancia de Mahalanobis $D_M(x) = \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)}$ es estrictamente invariante ante cualquier transformación lineal de rango completo $y = Cx$.
14. **Relación Métrica Euclídea:** Pruebe que si las variables observadas son de varianza constante y no tienen correlación entre sí ($\Sigma = c^2 I$), la métrica de Mahalanobis converge matemáticamente a una distancia Euclídea estandarizada por un factor de $1/c$.
15. **Geometría del Hiper-elipsoide:** La matriz Σ es definida positiva, por ende diagonalizable como $\Sigma = U \Lambda U^T$. Utilizando este teorema espectral, reescriba $D_M(x)$ en el espacio de los ejes principales (autovectores) y demuestre que la ecuación $D_M(x)^2 = c^2$ corresponde a la fórmula analítica de un hiper-elipsoide.
16. **Divergencia KL y Distancia Mahalanobis:** Si $P \sim \mathcal{N}(\mu_1, \Sigma)$ y $Q \sim \mathcal{N}(\mu_2, \Sigma)$, demuestre que la Divergencia de Kullback-Leibler $D_{KL}(P||Q)$ es proporcional al cuadrado de la distancia de Mahalanobis entre sus medias μ_1 y μ_2 .

Parte V: Modelado Probabilístico de Valores Faltantes (Taxonomía de Rubin)

17. **Descomposición de Verosimilitud (MAR):** Bajo el mecanismo Missing At Random (MAR), $P(R|X_{obs}, X_{miss}) = P(R|X_{obs})$. Mediante la integración sobre la distribución conjunta, demuestre por qué la función de verosimilitud se puede factorizar permitiendo la ignorabilidad (ignorability) del mecanismo faltante para inferir parámetros de los datos.
18. **Insesgadez de Estimadores bajo MCAR:** Pruebe que si un mecanismo es Missing Completely at Random (MCAR) con probabilidad constante de pérdida p , el estimador de la media muestral calculada únicamente sobre los casos completos $\bar{x}_{cc}$ es un estimador estadísticamente insesgado de la media poblacional μ .

19. **Sesgo Sistemático en MNAR:** Asuma $Y \sim \mathcal{N}(\mu, \sigma^2)$. Si Y falta estrictamente cuando $Y > c$ (mecanismo Missing Not at Random), calcule analíticamente el sesgo de la media observada $E[Y_{obs}] - \mu$ usando las propiedades de la distribución normal truncada y demuestre que el sesgo es siempre negativo.
20. **Distorsión por Imputación Incondicional:** Suponga que se aplica imputación simple reemplazando todos los valores faltantes de una variable (bajo mecanismo MAR) con la media muestral de sus valores observados. Demuestre algebraicamente que esta técnica infla artificialmente la concentración alrededor de la media, reduciendo falsamente la varianza de la variable imputada y subestimando la matriz de covarianza real.