

CONA PD 2

1) Sea $T: \mathbb{R}^d \rightarrow \mathbb{R}^k$ TL
 $x \mapsto T(x) = Ax$ / $A \in \mathbb{R}^{k \times d}$
 $x \in \mathbb{R}^d \approx \mathbb{R}^{d-1}$

S: $A^T A = I$

Demstrar $d(x_i, x_j) = d(Tx_i, Tx_j)$

De fato:

$$\begin{aligned} d^2(Tx_i, Tx_j) &= \|Tx_i - Tx_j\|^2 = \|T(x_i - x_j)\|^2 = \|A(x_i - x_j)\|^2 \\ &= (A(x_i - x_j))^T (A(x_i - x_j)) \\ &= (x_i - x_j)^T \underbrace{A^T A}_{=I} (x_i - x_j) = (x_i - x_j)^T (x_i - x_j) \\ &= \|x_i - x_j\|^2 \end{aligned}$$

o. $d(x_i, x_j) = d(Tx_i, Tx_j)$ cuando $A^T A = I$

2) Sea T un operador. d. s. f. o. r.

$$\begin{aligned} T: \mathbb{R}^2 &\rightarrow \mathbb{R}^2 \\ x &\mapsto T(x) = Ax \quad / \quad A = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \end{aligned}$$

con $\lambda_1 \gg \lambda_2$.

Sea función de costo $J: \mathbb{R}^2 \rightarrow \mathbb{R}$
 $x \mapsto J(x) = \frac{1}{2} \|Ax\|_2^2$

PD: Distancia de la función costo
 Explique por qué se utiliza el gradiente descendente.

Defecto
 * Sea $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in \mathbb{R}^2 = \mathbb{R}^{2 \times 1}$.

$$\Rightarrow Tx = Ax = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} \lambda_1 x_1 \\ \lambda_2 x_2 \end{pmatrix} \in \mathbb{R}^{2 \times 1}$$

$$\Rightarrow \|Tx\|^2 = \lambda_1^2 x_1^2 + \lambda_2^2 x_2^2$$

$$\Rightarrow J(x) = \frac{1}{2} [\lambda_1^2 x_1^2 + \lambda_2^2 x_2^2]$$

$$\begin{aligned} \cdot \nabla J(x) &= \begin{pmatrix} \lambda_1^2 x_1 \\ \lambda_2^2 x_2 \end{pmatrix} = \begin{pmatrix} \lambda_1^2 & 0 \\ 0 & \lambda_2^2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ &= \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}^T \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = A^T A x \end{aligned}$$

$$\text{Así: } A^T A = \begin{pmatrix} \lambda_1^2 & 0 \\ 0 & \lambda_2^2 \end{pmatrix}$$

$$\cdot HJ(x) = \begin{pmatrix} \lambda_1^2 & 0 \\ 0 & \lambda_2^2 \end{pmatrix}$$

Así: los valores propios de $HJ(x)$ nos dan las direcciones principales de la curvatura.

Los valores propios de $HJ(x)$ son

$$\mu_1 = \lambda_1^2, \mu_2 = \lambda_2^2 \text{ y como } \lambda_1 \gg \lambda_2$$

$$\Rightarrow \lambda_1^2 \gg \lambda_2^2 \Rightarrow \mu_1 \gg \mu_2$$

Así: la curvatura en la dirección x_1 es mucho mayor que en la dirección x_2 de la función coste.

Veamos la distancia de la métrica.

$$\begin{aligned}
 \|T(x) - T(y)\|_2^2 &= \|T(x-y)\|_2^2 = \|A(x-y)\|_2^2 \\
 &= (A(x-y))^T (A(x-y)) \\
 &= (x-y)^T \underbrace{A^T A}_{\lambda_1^2 \quad 0 \quad 0 \quad \lambda_2^2} (x-y) \\
 &= (x-y)^T \begin{pmatrix} \lambda_1^2 & 0 \\ 0 & \lambda_2^2 \end{pmatrix} (x-y) \\
 &= [x_1 - y_1 \quad x_2 - y_2] \begin{pmatrix} \lambda_1^2 & 0 \\ 0 & \lambda_2^2 \end{pmatrix} \begin{pmatrix} x_1 - y_1 \\ x_2 - y_2 \end{pmatrix} \\
 &= [x_1 - y_1 \quad x_2 - y_2] \begin{pmatrix} \lambda_1^2 (x_1 - y_1) \\ \lambda_2^2 (x_2 - y_2) \end{pmatrix} \\
 &= \lambda_1^2 (x_1 - y_1)^2 + \lambda_2^2 (x_2 - y_2)^2 \\
 \Rightarrow \|T(x) - T(y)\|_2^2 &= \lambda_1^2 (x_1 - y_1)^2 + \lambda_2^2 (x_2 - y_2)^2
 \end{aligned}$$

Como $\lambda_1 \gg \lambda_2$, entonces la diferencia en la primera coordenada se amplifica mucho con respecto a la segunda coordenada.

* Veamos ahora que pasa en la convergencia del gradiente descendente.

$$x^{(k+1)} = x^{(k)} - \eta \nabla J(x^{(k)}) \quad \eta > 0$$

$$\Rightarrow x^{(k+1)} = x^{(k)} - \eta A^T A x^{(k)}$$

$$\Rightarrow x^{(k+1)} = (I - \eta A^T A) x^{(k)}$$

$$\Rightarrow X^{(k+1)} = \begin{pmatrix} 1 - \eta \lambda_1^2 & 0 \\ 0 & 1 - \eta \lambda_2^2 \end{pmatrix} X^{(k)}$$

$$\Rightarrow \begin{cases} X_1^{(k+1)} = (1 - \eta \lambda_1^2) X_1^{(k)} \\ X_2^{(k+1)} = (1 - \eta \lambda_2^2) X_2^{(k)} \end{cases}$$

Para cada sucesión sean convergente.

$$\begin{cases} |1 - \eta \lambda_1^2| < 1 \\ |1 - \eta \lambda_2^2| < 1 \end{cases} \Rightarrow \begin{cases} 0 < \eta < 2/\lambda_1^2 \\ 0 < \eta < 2/\lambda_2^2 \end{cases}$$

Para caso $\lambda_1 \gg \lambda_2 \Rightarrow \frac{2}{\lambda_1^2} \ll \frac{2}{\lambda_2^2}$

$$\Rightarrow 0 < \eta < \frac{2}{\lambda_1} \quad \text{so } \eta \in \left(0, \frac{2}{\lambda_1}\right)$$

Así la tasa de aprendizaje pequeña por la covarianza λ_1

Ahora definimos $g : \left(0, \frac{2}{\lambda_1}\right) \rightarrow \mathbb{R}$

$$\text{tg } g(\eta) = \max\{|1 - \eta \lambda_1^2|, |1 - \eta \lambda_2^2|\} \quad \eta \mapsto g(\eta)$$

Definimos $e^{(k)} = X^{(k)} - X^*$ (Vector error)

Donde X^* es el mínimo de $J \Rightarrow X^* = 0$

$$\Rightarrow e^{(k)} = X^{(k)} \quad \forall k.$$

CONA

$$\mathbf{e}^{(k+1)} = (\mathbf{I} - \eta \mathbf{A}^T \mathbf{A}) \mathbf{e}^{(k)}$$

$$\rightarrow \mathbf{e}^{(k)} = \begin{pmatrix} e_1^{(k)} \\ e_2^{(k)} \end{pmatrix}, \quad \mathbf{e}^{(k+1)} = \begin{pmatrix} (1 - \eta \lambda_1^2) e_1^{(k)} \\ (1 - \eta \lambda_2^2) e_2^{(k)} \end{pmatrix}$$

$$y \quad 0 < \eta < 1$$

$$\begin{aligned} \Rightarrow \|\mathbf{e}^{(k+1)}\|^2 &= (1 - \eta \lambda_1^2)^2 (e_1^{(k)})^2 + (1 - \eta \lambda_2^2)^2 (e_2^{(k)})^2 \\ &\leq \eta^2 (e_1^{(k)})^2 + \eta^2 (e_2^{(k)})^2 \\ &= \eta^2 [(e_1^{(k)})^2 + (e_2^{(k)})^2] = \eta^2 \|\mathbf{e}^{(k)}\|^2 \end{aligned}$$

$$\Rightarrow \|\mathbf{e}^{(k+1)}\| \leq \eta \|\mathbf{e}^{(k)}\|$$

$$\Rightarrow \frac{\|\mathbf{e}^{(k+1)}\|}{\|\mathbf{e}^{(k)}\|} \leq \eta < 1$$

$$\Rightarrow \lim_{k \rightarrow \infty} \frac{\|\mathbf{e}^{(k+1)}\|}{\|\mathbf{e}^{(k)}\|} < 1 \quad \text{Converge linealmente}$$

Para ver como η se comporta:

Vamos a ver cómo se comporta η minimizando

$$\eta \in \left\langle \frac{1}{\lambda_1^2}, \frac{1}{\lambda_2^2} \right\rangle$$

$$\text{Esto se debe } \lambda_1 > \lambda_2 \Rightarrow \frac{1}{\lambda_1} < \frac{1}{\lambda_2}$$

$$\Rightarrow \frac{1}{\lambda_1^2} < \eta < \frac{1}{\lambda_2^2} \Rightarrow 1 - \eta \lambda_1^2 < 0 \wedge 0 < 1 - \eta \lambda_2^2$$

Así

$$\eta \in \left\langle \frac{1}{\lambda_1^2}, \frac{1}{\lambda_2^2} \right\rangle \quad \eta \in \left\langle \frac{1}{\lambda_1^2}, \frac{1}{\lambda_2^2} \right\rangle$$

Juntos construimos tu mejor

CONA

$$\rightarrow f(\eta) = \max_{\eta \in \left\{ \frac{1}{\lambda_1^2}, \frac{1}{\lambda_2^2} \right\}} \{ f(\eta), g(\eta) \}$$

El mínimo se da cuando $f(\eta) = g(\eta)$

$$f(\eta) = g(\eta) \Rightarrow \eta \lambda_1^2 - 1 = 1 - \eta \lambda_2^2$$

$$\Rightarrow \eta^* = \frac{2}{\lambda_1^2 + \lambda_2^2}$$

Reemplazando η^* en $g(\eta)$, o cualquiera de los dos términos de $f(\eta)$, tenemos:

$$\Rightarrow f(\eta) = 1 - \frac{2\lambda_2^2}{\lambda_1^2 + \lambda_2^2} \quad (11)$$

La condición espectral para una matriz simétrica es

$$K(H) = \frac{\lambda_{\max}(H)}{\lambda_{\min}(H)}$$

Para nuestro caso $H = H^T A$

$$\Rightarrow \lambda_{\max} = \lambda_1^2, \quad \lambda_{\min} = \lambda_2^2 \Rightarrow K = \frac{\lambda_1^2}{\lambda_2^2}$$

En (11) tenemos

$$f(\eta) = \frac{\lambda_1^2 - \lambda_2^2}{\lambda_1^2 + \lambda_2^2} = \frac{\left(\frac{\lambda_1^2}{\lambda_2^2}\right) - 1}{\left(\frac{\lambda_1^2}{\lambda_2^2}\right) + 1} = \frac{K-1}{K+1} = 1 - \frac{2}{K+1}$$

$$\text{Como } \lambda_1 \gg \lambda_2 \Rightarrow \lambda_1^2 \gg \lambda_2^2 \Rightarrow K = \frac{\lambda_1^2}{\lambda_2^2} \gg 1$$

$\Rightarrow f(\eta) \rightarrow 1$ esto quiere decir
 $K \gg 1$ la sucesión converge cada vez a más
 hasta $\lim_{k \rightarrow \infty} \eta_k = 1 = f(\eta)$

3. Sea T b -Lipschitz. entonces $d(x, x_j) \approx d(Tx, Tx_j)$
 Establezcamos y demostraremos, límites inferiores del
 error de vecindad, que el algoritmo k -NN podría
 sufrir tras aplicar T .

Sea

Sea $T: \mathbb{R}^d \rightarrow \mathbb{R}^k$ es b -Lipschitz

$\exists m, L \in \mathbb{R} / 0 < m \leq L < \infty$. $\forall x, y$

$$m \|x - y\|_2 \leq \|Tx - Ty\|_2 \leq M \|x - y\|_2 \quad \forall x, y$$

Entonces pasando a la distancia

$$m d(x, y) \leq d(Tx, Ty) \leq M d(x, y)$$

$$\Rightarrow m \leq \frac{d(Tx, Ty)}{d(x, y)} \leq M.$$

$$\text{Haciendo } m = 1 - f, \quad M = 1 + f \text{ con } f = \frac{M - m}{2}$$

$$\Rightarrow 1 - f \leq \frac{d(Tx, Ty)}{d(x, y)} \leq 1 + f$$

$$\Rightarrow -f \leq \frac{d(Tx, Ty)}{d(x, y)} - 1 \leq f$$

$$\Rightarrow \text{Error Relativo} \left| \frac{d(Tx, Ty)}{d(x, y)} - 1 \right| \leq f$$

El error relativo de la distancia está acotado por f

A₄: Sea T bilipschitz entonces T es homeomorfo.

• T es suryectiva:

$$\text{Sea } T(x) = T(y) \Rightarrow \|T(x) - T(y)\|_2 = 0$$

Por ser T bilipschitz $\exists M, m > 0$ con $m > 0$ t.q.

$$m\|x - y\|_2 \leq \|T(x) - T(y)\|_2 \leq M\|x - y\|_2$$

$$\Rightarrow m\|x - y\|_2 \leq 0 \Rightarrow \|x - y\|_2 = 0 \Rightarrow x = y.$$

Así: T es inyectiva

• T continua:

Por ser T bilipschitz, $\exists M > 0$ t.q.

$$\|T(x) - T(y)\|_2 \leq M\|x - y\|_2$$

$\Rightarrow T$ es continua

• T^{-1} es continua:

T bilipschitz $\Rightarrow \exists m > 0$ t.q.

$$m\|x - y\|_2 \leq \|T(x) - T(y)\|_2 \quad \forall x, y$$

Haciendo $T(x) = u$, $T(y) = v \Rightarrow x = T^{-1}(u)$, $y = T^{-1}(v)$

$$\Rightarrow \|T^{-1}(u) - T^{-1}(v)\|_2 \leq \frac{1}{m} \|u - v\|_2$$

$\Rightarrow T^{-1}$ es continua en $T(\mathbb{R}^d)$

Así hemos demostrado

- T es lineal
- T es sobreyectivo en $T(\mathbb{R}^d)$ ($T: \mathbb{R}^d \rightarrow T(\mathbb{R}^d)$)
- T es continua
- T^{-1} es continua

$\Rightarrow T$ es homeomorfo.

Veamos que pasa con las vecindades.

$$\underline{A_1}: T(B_\varepsilon(x)) \subseteq B_{M\varepsilon}(Tx)$$

De fato:

$$\text{Sea } y \in T(B_\varepsilon(x)), \exists z \in B_\varepsilon(x) / y = T(z)$$

$$\Rightarrow \|x - z\| < \varepsilon$$

Pro

$$\|y - Tx\| = \|T(z) - Tx\| \leq M\|x - z\| \leq M\varepsilon$$

$$\Rightarrow y \in B_{M\varepsilon}(Tx)$$

$$\text{Se } T(B_\varepsilon(x)) \subseteq B_{M\varepsilon}(Tx)$$

$$\underline{A_2}: B_{M\varepsilon}(Tx) \cap T(\mathbb{R}^d) \subseteq T(B_\varepsilon(x))$$

$$\text{Sea } y \in B_{M\varepsilon}(Tx) \cap T(\mathbb{R}^d)$$

$$\Rightarrow y \in B_{M\varepsilon}(Tx) \wedge y \in T(\mathbb{R}^d)$$

$$\Rightarrow \exists z \in \mathbb{R}^d / T(z) = y \wedge \|y - Tx\| < M\varepsilon$$

$$\Rightarrow \|T(z) - T(x)\| < M\varepsilon, \quad y = T(z)$$

Remember

$$M\|z - x\| \leq \|T(z) - T(x)\| < M\varepsilon \Rightarrow \|z - x\| < \varepsilon$$

$$\Rightarrow z \in B_\varepsilon(x) \wedge y = T(z) \Rightarrow y = T(z) \in T(B_\varepsilon(x))$$

$$\text{as: } B_{M\varepsilon}(T(x)) \cap T(\mathbb{R}^d) \subseteq T(B_\varepsilon(x))$$

De las 2 últimas afirmaciones tenemos.


$$B_{\varepsilon M}(Tx) \cap T(\mathbb{R}^d) \subseteq T(B_\varepsilon(x)) \subseteq B_{\varepsilon M}(Tx) \dots (II)$$

Así esta inclusión (II) significa que cualquier bda (Vecindad) del Espacio original, al aplicarlo una T bi-Lipschitz este queda atrapado entre dos bda's, uno lo mayor y el otro lo menor.

- Para nuestro algoritmo k -NN. sean los pts. del conjunto de datos $x_1, x_2, \dots, x_n$ y sea el pto x a consultar.
Entonces definimos la distancia de x hacia cada x_i como

$$r_i = d(x, x_i) \quad \forall i$$

$$r_1 \leq r_2 \leq \dots \leq r_n$$



CONA

Los K vecinos son $x_1, x_2, \dots, x_K$
con las distancias $r_1, r_2, \dots, r_K$

Aplicando T , a los datos y luego calculamos
las distancias, así definimos

$$\bar{r}_i := d(Tx, Tx_i), \quad i \in \{1, K\}$$

Por ser T bilipchitz tenemos $m, M > 0$ tq

$$m \|x - x_i\| \leq d(Tx, Tx_i) \leq M \|x - x_i\|$$

$$\Rightarrow m d(x, x_i) \leq d(Tx, Tx_i) \leq M d(x, x_i)$$

$$\Rightarrow m r_i \leq \bar{r}_i \leq M r_i \quad \forall i \in \{1, K\}.$$

Así los datos, la distancia se modifica en
forma acotada. ▲

(4) Si $X_{obs} = X_{true} + \varepsilon$ donde X_{true}, ε son var. aleatorias independientes.

Entonces $Var(X_{obs}) = Var(X_{true}) + Var(\varepsilon)$

Sea $X_{true} \in \mathbb{R}^d$, $\varepsilon \in \mathbb{R}^d$

Calculando los momentos tenemos:

$$\mu_{true} = E[X_{true}], \mu_{\varepsilon} = E[\varepsilon], \mu_{obs} = E[X_{obs}]$$

$$\Rightarrow \mu_{obs} = E[X_{obs}] = E[X_{true} + \varepsilon] = E[X_{true}] + E[\varepsilon]$$

$$\Rightarrow \mu_{obs} = \mu_{true} + \mu_{\varepsilon}$$

Recordar la definición de Varianza:

$$Var(X) = E[(X - \mu)(X - \mu)^t]$$

Para nuestro X_{obs} tenemos:

$$\begin{aligned} X_{obs} - \mu_{obs} &= X_{true} + \varepsilon - \mu_{obs} = X_{true} + \varepsilon - \mu_{true} - \mu_{\varepsilon} \\ &= (X_{true} - \mu_{true}) + (\varepsilon - \mu_{\varepsilon}) \end{aligned}$$

$$\begin{aligned} \Rightarrow Var(X_{obs}) &= E[(X_{obs} - \mu_{obs})(X_{obs} - \mu_{obs})^t] \\ &= E\left[\underbrace{(X_{true} - \mu_{true})}_A + \underbrace{(\varepsilon - \mu_{\varepsilon})}_B\right]\left[\underbrace{(X_{true} - \mu_{true})}_A + \underbrace{(\varepsilon - \mu_{\varepsilon})}_B\right]^t \end{aligned}$$

$$Var(X_{obs}) = E[(A+B)(A+B)^t] = E[AA^t + AB^t + BA^t + BB^t]$$

$$= E[AA^t + BA^t + AB^t + BB^t]$$

$$= E[AA^t] + E[BA^t] + E[AB^t] + E[BB^t]$$

CONA

$$\Rightarrow \text{Var}(X_{\text{obs}}) = \mathbb{E}[(X_{\text{true}} - \mu_{\text{true}})(X_{\text{true}} - \mu_{\text{true}})^T] + \mathbb{E}[(\varepsilon - \mu_{\varepsilon})(X_{\text{true}} - \mu_{\text{true}})^T] \\ + \mathbb{E}[(X_{\text{true}} - \mu_{\text{true}})(\varepsilon - \mu_{\varepsilon})^T] + \mathbb{E}[(\varepsilon - \mu_{\varepsilon})(\varepsilon - \mu_{\varepsilon})^T]$$

$$\Rightarrow \text{Var}(X_{\text{obs}}) = \text{Var}(X_{\text{true}}) + \text{Cov}(\varepsilon, X_{\text{true}}) + \text{Cov}(X_{\text{true}}, \varepsilon) + \text{Var}(\varepsilon)$$

Por hip X_{true} y ε son independientes

$$\Rightarrow \text{Cov}(\varepsilon, X_{\text{true}}) = \text{Cov}(X_{\text{true}}, \varepsilon) = 0$$

$$\Rightarrow \text{Var}(X_{\text{obs}}) = \text{Var}(X_{\text{true}}) + \text{Var}(\varepsilon) \quad \blacktriangle$$

Sea $\varepsilon \sim N(0, \sigma^2 I)$

Entonces $\lambda_{i,obs} = \lambda_{i,true} + \sigma^2$

Sol

Notación: $\text{Var}(X) = \Sigma_X$

De lo anterior se tiene, para $\varepsilon \sim N(0, \sigma^2 I)$ se tiene:

$$\text{Var}(X_{obs}) = \text{Var}(X_{true}) + \text{Var}(\varepsilon)$$

$$\Rightarrow \Sigma_{X_{obs}} = \Sigma_{X_{true}} + \Sigma_{\varepsilon} = \Sigma_{X_{true}} + \sigma^2 I$$

$$\therefore \Sigma_{X_{obs}} = \Sigma_{X_{true}} + \sigma^2 I$$

Veamos los polinomios característicos de Σ_{obs} , Σ_{true} .

$$\begin{aligned} \bullet P_{obs}(\lambda) &= |\Sigma_{obs} - \lambda I| = |\Sigma_{true} + \sigma^2 I - \lambda I| \\ &= |\Sigma_{true} - (\lambda - \sigma^2) I| \end{aligned}$$

$$\bullet P_{true}(t) = |\Sigma_{true} - t I|$$

• De P_{obs} y P_{true} se tiene

$$P_{obs}(\lambda) = P_{true}(\lambda - \sigma^2)$$

Sea $\lambda_{i,true}$ un autovalor de Σ_{true} .

$$\Rightarrow P_{true}(\lambda_{i,true}) = 0$$

Veamos los valores que anulan a P_{obs}

$$0 = P_{obs}(\lambda) = P_{true}(\lambda - \sigma^2)$$

$$\Rightarrow P_{true}(\lambda - \sigma^2) = 0$$

Así los valores que anulan P_{true} son:

$$\lambda_{1,true}, \lambda_{2,true}, \dots, \lambda_{d,true}.$$

tal que

$$\lambda - \sigma^2 = \lambda_{i,true}$$

$$\Rightarrow \lambda_{i,obs} - \sigma^2 = \lambda_{i,true}$$

$$\Leftrightarrow \lambda_{i,obs} = \lambda_{i,true} + \sigma^2$$



Sea $\varepsilon \sim N(0, \sigma^2 I) \leftarrow$ (ruido isotrópico)

$$\text{con } \Sigma_{\text{obs}} = \Sigma_{\text{true}} + \sigma^2 I$$

$$\text{y } \lambda_{i,\text{obs}} = \lambda_{i,\text{true}} + \sigma^2$$

Entonces

$$V_{i,\text{obs}} = V_{i,\text{true}}$$

donde $V_{i,\text{obs}}$ autovector de Σ_{obs}
 $V_{i,\text{true}}$ " " Σ_{true}

Sol
 Por definición tenemos:

$$\begin{cases} \Sigma_{\text{obs}} V_{i,\text{obs}} = \lambda_{i,\text{obs}} V_{i,\text{obs}} \\ \Sigma_{\text{true}} V_{i,\text{true}} = \lambda_{i,\text{true}} V_{i,\text{true}} \end{cases}$$

Ahora veamos:

$$\begin{aligned} \Sigma_{\text{obs}} V_{i,\text{true}} &= (\Sigma_{\text{true}} + \sigma^2 I) V_{i,\text{true}} \\ &= \Sigma_{\text{true}} V_{i,\text{true}} + \sigma^2 V_{i,\text{true}} \\ &= \lambda_{i,\text{true}} V_{i,\text{true}} + \sigma^2 V_{i,\text{true}} \end{aligned}$$

$$\Rightarrow \Sigma_{\text{obs}} V_{i,\text{true}} = (\lambda_{i,\text{true}} + \sigma^2) V_{i,\text{true}}$$

Así tenemos:

$$\begin{cases} \Sigma_{\text{obs}} V_{i,\text{true}} = \lambda_{i,\text{obs}} V_{i,\text{true}} \\ \Sigma_{\text{obs}} V_{i,\text{obs}} = \lambda_{i,\text{obs}} V_{i,\text{obs}} \end{cases}$$

$$\Rightarrow V_{i,\text{true}} = V_{i,\text{obs}}$$